

ใบงานที่ 4 การสร้างและประเมินผลโมเดลการเรียนรู้แบบมีผู้สอน (Supervised Learning)

วัตถุประสงค์การเรียนรู้

1. เขียนคำสั่ง Python เพื่อจัดการข้อมูลสูญหาย (Missing Data) ด้วยวิธีการลบแถวได้ถูกต้อง
2. กำหนดตัวแปร Feature (X) และ Target (y) ให้สอดคล้องกับโจทย์ Regression ได้ถูกต้อง
3. เขียนคำสั่ง Python เพื่อสร้าง ฝึกสอน (Train) บันทึกลง และโหลดโมเดล Linear Regression เพื่อนำไปใช้งานจริงได้
4. ประเมินประสิทธิภาพโมเดล (MAE, RMSE, R^2) และอธิบายความสัมพันธ์ของตัวแปรที่มีผลต่อการทำนายได้

เครื่องมือและอุปกรณ์

1. เครื่องคอมพิวเตอร์ที่ติดตั้งโปรแกรม PyCharm IDE
2. ไฟล์ข้อมูลดิบ lab2.csv
3. เอกสารใบความรู้หน่วยที่ 4
4. แบบฟอร์มบันทึกผลการปฏิบัติงาน (ท้ายใบงาน)

ลำดับขั้นตอนการปฏิบัติงาน

คำชี้แจง: ให้ผู้เรียนเขียนโค้ดลงในไฟล์ตามขั้นตอนต่อไปนี้

ขั้นตอนที่ 1: การเตรียมข้อมูล (Data Preparation)

```
# 1. นำไฟล์ lab2.csv จากโฟลเดอร์ Data management มาเป็น Dataset สำหรับ AI ประมาณราคาบ้าน
# 2. สร้างไฟล์ใหม่ชื่อ clean_data.py
import pandas as pd

# 3. เขียนคำสั่งโหลดไฟล์ lab2.csv
print("กำลังโหลดข้อมูล...")
df = pd.read_csv('lab2.csv')
```

```
# 4. ตรวจสอบและทำความสะอาด
```

```
print(f"ข้อมูลทั้งหมด: {len(df)} แถว")
```

```
# 5. เลือกคอลัมน์ที่ต้องการใช้ (Features & Target)
```

```
data = df[['SquareMeters', 'Bedrooms', 'HouseAge', 'DistanceToBTS', 'Price']]
```

```
# 6. เขียนคำสั่งลบแถวที่มีข้อมูลสูญหาย (Missing Values)
```

```
data_clean = data.dropna()
```

```
# 7. แสดงจำนวนแถวที่เหลือ
```

```
print(f"หลังทำความสะอาดเหลือ: {len(data_clean)} แถว")
```

```
# 8. บันทึกไฟล์ใหม่ที่สะอาดแล้วเป็นไฟล์ชื่อ house_price_clean.csv
```

```
data_clean.to_csv('house_price_clean.csv', index=False)
```

```
print("บันทึกไฟล์สำเร็จ: house_price_clean.csv")
```

ขั้นตอนที่ 2: การสร้างและสอนโมเดล (Model Training)

```
# 1. สร้างไฟล์ใหม่ชื่อ train_model.py
```

```
import pandas as pd
```

```
import numpy as np
```

```
from sklearn.model_selection import train_test_split
```

```
from sklearn.linear_model import LinearRegression
```

```
from sklearn import metrics
```

```
import joblib
```

```
# 2. โหลดไฟล์ house_price_clean.csv
```

```
data = pd.read_csv('house_price_clean.csv')
```

```
# 3. กำหนดตัวแปร X (Features) และ y (Target)
```

```
X = data[['SquareMeters', 'Bedrooms', 'HouseAge', 'DistanceToBTS']]
```

```
y = data['Price']
```

```

# 4. แบ่งข้อมูลเป็น Train Set (80%) และ Test Set (20%) โดยกำหนด random_state=42
X_train, X_test, y_train, y_test = train_test_split(X, y, test_size=0.2, random_state=42)

# 5. สร้างและสอนโมเดล (Training)
print("กำลังฝึกฝนโมเดล...")
model = LinearRegression()
model.fit(X_train, y_train)
print("ฝึกฝนเสร็จสิ้น!")

# 6. ประเมินผลโมเดล (Evaluation)
y_pred = model.predict(X_test)

# 7. คำนวณค่า MAE, RMSE, และ R^2 Score
mae = metrics.mean_absolute_error(y_test, y_pred)
rmse = np.sqrt(metrics.mean_squared_error(y_test, y_pred))
r2 = metrics.r2_score(y_test, y_pred)

print(f"\nผลการประเมินประสิทธิภาพ:")
print(f" - MAE: {mae:.2f} บาท")
print(f" - RMSE: {rmse:.2f} บาท")
print(f" - R2 Score: {r2:.4f}")

# 8. บันทึกโมเดล (Save Model)
joblib.dump(model, 'house_price_model.pkl')
print("\nบันทึกโมเดลไว้ที่: house_price_model.pkl")

```

ขั้นตอนที่ 3: การนำโมเดลไปใช้งาน (Deployment)

```

# 1. สร้างไฟล์ใหม่ชื่อ run_model.py
import pandas as pd
import joblib

```

```

# 2. โหลดไฟล์โมเดล house_price_model.pkl
print("กำลังโหลดโมเดล...")

model = joblib.load('house_price_model.pkl')

# 3. สร้างชุดข้อมูลจำลอง (Test Cases)
# โจทย์: ให้ประเมินราคาของบ้าน 3 หลังนี้
test_cases = [
    # กรณีที่ 1: คอนโดกลางเมือง (พื้นที่น้อย, ใกล้รถไฟฟ้า)
    {'SquareMeters': 35, 'Bedrooms': 1, 'HouseAge': 2, 'DistanceToBTS': 0.2},

    # กรณีที่ 2: บ้านเดี่ยวชานเมือง (พื้นที่เยอะ, ใกล้รถไฟฟ้า)
    {'SquareMeters': 200, 'Bedrooms': 4, 'HouseAge': 10, 'DistanceToBTS': 4.5},

    # กรณีที่ 3: ทาวน์โฮมเก่า (พื้นที่กลางๆ, อายุเยอะ)
    {'SquareMeters': 120, 'Bedrooms': 3, 'HouseAge': 25, 'DistanceToBTS': 2.0}
]

print("\nผลการประเมินราคาบ้าน:")
print("=" * 50)

# 4. เขียนคำสั่งให้โมเดลประเมินราคาขายของทั้ง 3 กรณี
for case in test_cases:
    X_input = pd.DataFrame([case])

    predicted_price = model.predict(X_input)[0]

    print(f"บ้านสเปค: {case}")
    print(f"ราคาประเมิน: {predicted_price:,.2f} บาท")
    print("-" * 50)

```

แบบบันทึกผลการปฏิบัติงาน

ส่วนที่ 1: ผลการเตรียมข้อมูล (Data Cleaning Results)

ตรงกับวัตถุประสงค์การเรียนรู้ข้อที่ 1 และ 2: (การจัดการข้อมูลสูญหายด้วยการลบแถว และการกำหนดตัวแปร Feature/Target)

คำชี้แจง: ให้ดูผลลัพธ์จากหน้าจอ Terminal หลังรันคำสั่ง แล้วบันทึกค่าที่ได้ลงในช่องว่าง

1. จำนวนข้อมูลดิบทั้งหมด (Original Rows): 100 แถว
2. จำนวนข้อมูลที่เหลือหลังทำความสะอาด (Cleaned Rows): 95 แถว
3. คอลัมน์ที่เป็น Feature (ตัวแปรต้น) ได้แก่?

SquareMeters, Bedrooms, HouseAge, DistanceToBTS

4. คอลัมน์ที่เป็น Target (ตัวแปรตาม) คือ?

Price

ส่วนที่ 2: ผลการประเมินประสิทธิภาพโมเดล (Model Evaluation)

ตรงกับวัตถุประสงค์การเรียนรู้ข้อที่ 4: (ประเมินประสิทธิภาพโมเดล MAE, RMSE, R²)

1. MAE (Mean Absolute Error):
 - โดยเฉลี่ยแล้ว โมเดลจะทายผิดไป 307,981.49 บาท
2. RMSE (Root Mean Squared Error):
 - โมเดลทายผิดไปมากที่สุด 357,130.08 บาท
3. R² Score:
 - ความแม่นยำในการอธิบายความสัมพันธ์ของข้อมูลคือ 0.9744 (หรือ 97.44 %)

ส่วนที่ 3: ผลการประเมินราคา (Prediction Results)

ตรงกับวัตถุประสงค์การเรียนรู้ข้อที่ 3: (สร้าง ฟังก์ชัน บ้านที่กิโล โหลด และนำโมเดลไปใช้งานจริง)

จงบันทึกราคาที่โมเดลประเมินได้จากกรณีศึกษาต่อไปนี้:

กรณีศึกษา (Scenario)	ข้อมูลนำเข้า (Input Features)	ราคาประเมิน (Predicted Price)
1. คอนโดกลางเมือง	35 ตร.ม. / 1 นอน / 2 ปี / BTS 0.2 กม.	2,615,252.76 บาท
2. บ้านเดี่ยวชานเมือง	200 ตร.ม. / 4 นอน / 10 ปี / BTS 4.5 กม.	6,909,051.42 บาท
3. ทาวน์โฮมเก่า	120 ตร.ม. / 3 นอน / 25 ปี / BTS 2.0 กม.	4,043,245.81 บาท

ส่วนที่ 4: คำถามท้ายการทดลอง (Conclusion)

ตรงกับวัตถุประสงค์การเรียนรู้ข้อที่ 4: (ประเมินและอธิบายความสัมพันธ์ของตัวแปรที่มีผลต่อการทำนาย)

คำชี้แจง: บันทึกขนาด (Shape) ของตัวแปรที่ได้จากการแบ่ง Train/Test

1. ในขั้นตอนการแบ่งข้อมูล (Split Data) หากเราไม่แบ่งข้อมูลเป็น Train และ Test (ใช้ข้อมูล 100% สอนโมเดลเลย) จะเกิดผลเสียอย่างไรในอนาคต?

แนวคำตอบ: จะทำให้เราไม่สามารถวัดประสิทธิภาพที่แท้จริงของโมเดลเมื่อเจอกับข้อมูลใหม่ๆ ได้ (เกิดภาวะ Overfitting) โมเดลอาจจะทำนายข้อมูลที่เคยท่องจำมา (Train data) ได้แม่นยำ 100% แต่เมื่อนำไปใช้งานจริงกับข้อมูลบ้านหลังใหม่ที่ไม่เคยเห็นมาก่อน โมเดลจะทำนายได้แย่และมีความคลาดเคลื่อนสูงมาก

2. จากกรณีศึกษาที่ 2 (บ้านเดี่ยวชานเมือง) และ กรณีศึกษาที่ 3 (ทาวน์โฮมเก่า) ทั้งที่มีพื้นที่ใช้สอย (SquareMeters) ต่างกันไม่มาก แต่ทำไมราคาประเมินถึงแตกต่างกัน? จงอธิบายโดยอ้างอิงตัวแปร (Feature) ที่เกี่ยวข้อง

แนวคำตอบ: ราคาที่แตกต่างกันเป็นผลมาจากตัวแปร "อายุบ้าน (HouseAge)" และ "ระยะห่างจากรถไฟฟ้า (DistanceToBTS)" เป็นสำคัญ แม้พื้นที่ใช้สอย (SquareMeters) จะมีขนาดไม่ต่างกันมาก แต่บ้านในกรณีศึกษาที่ 3 มีอายุบ้านที่มากกว่าถึง 15 ปี (25 ปี เทียบกับ 10 ปี) ซึ่งโมเดลเรียนรู้ว่ายิ่งบ้านเก่า ราคาจะยิ่งลดลง (ความสัมพันธ์เชิงลบ) แม้ว่าบ้านหลังที่ 3 จะอยู่ใกล้รถไฟฟ้ามากกว่าก็ตาม แต่น้ำหนักของอายุบ้านที่เก่ากว่ามากได้ลดราคาประเมินให้ต่ำกว่าบ้านเดี่ยวชานเมืองอย่างเห็นได้ชัด