

ใบความรู้ที่ 3 การจัดการและเตรียมข้อมูล (Data Preparation)

วัตถุประสงค์การเรียนรู้

1. รู้ความหมายและความสำคัญของการเตรียมข้อมูล (Data Preparation) ที่มีต่อประสิทธิภาพของโมเดล AI
2. เข้าใจหลักการและวิธีการจัดการกับปัญหาของข้อมูล ได้แก่ ข้อมูลสูญหาย (Missing Values) ข้อมูลซ้ำซ้อน (Duplicates) และข้อมูลผิดปกติ (Outliers)
3. เข้าใจความแตกต่างและหลักเกณฑ์การเลือกใช้วิธีปรับสเกลข้อมูลระหว่าง Normalization และ Standardization
4. รู้วิธีการแปลงข้อมูลข้อความให้เป็นตัวเลข (Encoding)
5. รู้วิธีการคัดเลือกคุณลักษณะ (Feature Selection) ที่จำเป็นต่อโมเดล
6. เข้าใจเหตุผลและความจำเป็นของการแบ่งชุดข้อมูล (Data Splitting) เป็นชุดฝึกสอน (Training Set) และชุดทดสอบ (Testing Set)

1. บทนำสู่ความสำคัญของการจัดการและเตรียมข้อมูล (Introduction)

ในการศึกษาเทคโนโลยีปัญญาประดิษฐ์ (Artificial Intelligence: AI) ความเข้าใจที่ถูกต้องเกี่ยวกับ "ข้อมูล" (Data) จึงเป็นรากฐานที่ไม่อาจละเลยได้ หากเปรียบ AI เป็นเครื่องยนต์อันทรงพลัง ข้อมูลก็เปรียบเสมือนเชื้อเพลิงที่หล่อเลี้ยงให้เครื่องยนต์นั้นทำงานได้ ปรากฏการณ์ที่เกิดขึ้นในวงการวิทยาศาสตร์ข้อมูล (Data Science) ที่ทั่วโลกยินย่นสอดคล้องกันว่า ความสำเร็จของโมเดล AI ไม่ได้ขึ้นอยู่กับความซับซ้อนของสถาปัตยกรรมโครงข่ายประสาทเทียม (Neural Network Architecture) เพียงอย่างเดียว แต่ขึ้นอยู่กับ "คุณภาพ" และ "ความพร้อม" ของข้อมูลที่ใช้ในการฝึกฝนเป็นสำคัญ

แต่ต้องอย่าลืมหลักการพื้นฐานที่สุดที่นักวิทยาศาสตร์ข้อมูลต้องยึดถือคือแนวคิด "Garbage In, Garbage Out" (GIGO) ซึ่งสะท้อนความจริงที่ว่า อัลกอริทึมทางคณิตศาสตร์ ไม่ว่าจะเป็น Linear Regression อย่างง่าย หรือ Deep Learning ที่ซับซ้อน ต่างก็เป็นเพียงกระบวนการประมวลผลทางตรรกะ หากข้อมูลนำเข้า (Input) เต็มไปด้วยความผิดพลาด สัญญาณรบกวน (Noise) หรือความไม่สอดคล้อง (Inconsistency) ผลลัพธ์ที่ได้ (Output) ย่อมมีความผิดพลาดและไม่สามารถนำไปใช้งานจริงได้ การเตรียมข้อมูลจึงไม่ใช่เพียงงานธุรการในการจัดเรียงตัวเลข แต่เป็นกระบวนการวิศวกรรมที่ต้องอาศัยความเข้าใจในสถิติและบริบทของข้อมูล (Domain Knowledge) เพื่อ "กลั่น" สารสนเทศที่บริสุทธิ์ออกมาให้ AI ได้เรียนรู้

2. การสำรวจและการทำความสะอาดข้อมูล (Data Discovery and Cleaning)

ก่อนที่จะข้อมูลจะพร้อมสำหรับกระบวนการคำนวณ ข้อมูลดิบ (Raw Data) มักจะอยู่ในสภาพที่กระจัดกระจายและไม่สมบูรณ์ การทำความสะอาดข้อมูล (Data Cleaning) จึงเป็นขั้นตอนแรกที่สำคัญอย่างยิ่ง เพื่อยกระดับคุณภาพของข้อมูล (Data Quality) ให้เหมาะสมกับมาตรฐานของอัลกอริทึม

2.1. การจัดการข้อมูลสูญหาย (Handling Missing Values)

57	36	Male	69000	Master	11	7000	6.5	Yellow
58		Male		Bachelor	5	5000	7	Pink
59	40	Female	75000	Master	14	3000	6.5	Purple

ข้อมูลสูญหาย (Missing Data) เป็นปรากฏการณ์ที่พบได้ทั่วไปในชุดข้อมูลจริง ซึ่งอาจเกิดจากความผิดพลาดของมนุษย์ (Human Error) อุปกรณ์เก็บข้อมูลขัดข้อง หรือการที่เจ้าของข้อมูลปฏิเสธที่จะให้ข้อมูล ปัญหานี้มีความสำคัญอย่างยิ่งในทางทฤษฎี เพราะอัลกอริทึมส่วนใหญ่ในไลบรารีมาตรฐาน เช่น Scikit-Learn ไม่สามารถประมวลผลค่าว่าง (Null/NaN) ได้ และการจัดการที่ไม่ถูกต้องอาจนำไปสู่ความลำเอียง (Bias) ของโมเดลได้

2.1.1. ทฤษฎีกลไกการเกิดข้อมูลสูญหาย

2.1.1.1. Missing Completely at Random (MCAR): การสูญหายเกิดขึ้นอย่างสุ่มสมบูรณ์ โดยไม่มีความสัมพันธ์ใดๆ กับค่าของตัวแปรนั้นเองหรือตัวแปรอื่นๆ ในชุดข้อมูล กรณีนี้การตัดข้อมูลทิ้งอาจไม่ส่งผลกระทบต่อความไม่ลำเอียงของข้อมูลที่เหลืออยู่


2.1.1.2. Missing at Random (MAR): ความน่าจะเป็นที่ข้อมูลจะสูญหายขึ้นอยู่กับข้อมูลที่มีอยู่ในตัวแปรอื่น เช่น ในแบบสอบถาม ผู้ที่มีอายุน้อยอาจมีแนวโน้มไม่ระบุรายได้มากกว่าผู้ที่มีอายุมาก การจัดการข้อมูลในกรณีนี้ต้องอาศัยเทคนิคการแทนที่ (Imputation) เพื่อรักษาโครงสร้างความสัมพันธ์ไว้

2.1.1.3. Missing Not at Random (MNAR): การสูญหายมีความสัมพันธ์กับค่าที่หายไปนั้นเอง เช่น ผู้ที่มีรายได้สูงมากอาจจงใจไม่กรอกช่องรายได้ กรณีนี้เป็นปัญหาที่ซับซ้อนที่สุดและอาจต้องใช้โมเดลเฉพาะในการประมาณค่า

2.1.2. กลยุทธ์การจัดการ: การลบ vs การแทนที่

2.1.2.1. การลบข้อมูล (Deletion) คือการลบแถว (Row) ที่มีข้อมูลไม่ครบองค์ประกอบทิ้ง วิธีนี้เหมาะสมที่สุดเมื่อข้อมูลที่หายไปเป็น Target Variable (ตัวแปรเป้าหมาย) เช่น หากเราต้องการสร้าง AI ทำนาย "รายได้" (Income) แต่ข้อมูลแถวนั้นไม่มีค่ารายได้ ข้อมูลชุดนั้นก็เปรียบเสมือนโจทย์ข้อสอบที่ไม่มีเฉลย ซึ่งไม่ก่อให้เกิดการเรียนรู้ในรูปแบบ Supervised Learning แต่มีข้อควรระวังคือการลบข้อมูลจำนวนมากอาจทำให้สูญเสียอำนาจการทดสอบทางสถิติ (Statistical Power) และอาจทำให้เกิดอคติหากข้อมูลไม่ได้หายไปแบบสุ่ม (Non-MCAR)

2.1.2.2. การแทนที่ข้อมูล (Imputation) สำหรับตัวแปรที่เป็น Feature (ตัวแปรคุณลักษณะ)
การลบแถวทิ้งอาจทำให้เสียข้อมูลที่มีค่าในคอลัมน์อื่นไป การแทนที่ค่า (Imputation) จึงเป็นทางเลือกที่ช่วยรักษาขนาดของตัวอย่างข้อมูลไว้



1) Mean Imputation (การแทนที่ด้วยค่าเฉลี่ย) คือใช้ค่าเฉลี่ยเลขคณิตของข้อมูลที่มีอยู่ทั้งหมดมาเติมในช่องว่าง เหมาะสำหรับข้อมูลเชิงปริมาณ (Numerical Data) ที่มีการแจกแจงแบบปกติ (Normal Distribution) และไม่มีค่าผิดปกติ (Outliers) ครอบคลุม เพราะการเติมด้วยค่าเฉลี่ยจะทำให้ความแปรปรวน (Variance) ของข้อมูลลดลง (เนื่องจากเราเติมค่าที่ไม่มีการเบี่ยงเบนจากค่ากลาง) ซึ่งอาจทำให้ช่วงความเชื่อมั่น (Confidence Interval) แคบกว่าความเป็นจริง

2) Imputation (การแทนที่ด้วยค่ามัธยฐาน) คือใช้ค่ากลางที่แบ่งข้อมูลออกเป็นสองส่วนเท่า ๆ กัน เหมาะสำหรับข้อมูลที่มีการแจกแจงแบบเบ้ (Skewed) หรือมี Outlier สูง เพราะค่ามัธยฐานมีความทนทาน (Robust) ต่อค่าสุดโต่งมากกว่าค่าเฉลี่ย

3) Mode Imputation (การแทนที่ด้วยฐานนิยม) คือการใช้ค่าที่มีความถี่สูงสุดในชุดข้อมูลเป็นวิธีหลักในการจัดการกับข้อมูลเชิงกลุ่ม (Categorical Data) เช่น เพศ หรือ ระดับการศึกษา

4) K-Nearest Neighbors (KNN) Imputation เป็นวิธีขั้นสูงที่ใช้แนวคิดของ "ความคล้ายคลึง" โดยอัลกอริทึมจะค้นหาข้อมูลจำนวน ตัวอย่างที่มีคุณลักษณะใกล้เคียงกับข้อมูลที่หายไปมากที่สุด (โดยคำนวณจากระยะทาง เช่น Euclidean Distance) แล้วนำค่าของเพื่อนบ้านเหล่านั้นมาเฉลี่ยกัน ทำให้ได้ผลลัพธ์ที่แม่นยำกว่าการใช้ค่ากลางรวม เพราะเป็นการประมาณค่าโดยอิงจากบริบทของตัวแปรอื่นๆ (Multivariate approach) ช่วยรักษาโครงสร้างความสัมพันธ์ของข้อมูลได้ดีกว่า

5) Deductive Imputation (การแทนที่ด้วยการอนุมาน) คือการใช้ตรรกะหรือความสัมพันธ์ที่แน่นอนระหว่างตัวแปร มาช่วยระบุค่าที่หายไป วิธีนี้ไม่ได้อาศัยค่าเฉลี่ยทางสถิติ แต่อาศัย "กฎ" (Rules) หรือ "ความรู้เฉพาะทาง" (Domain Knowledge) ที่ระบุได้ว่า "ถ้าตัวแปร A มีค่าเป็น X แล้วตัวแปร B ต้อง มีค่าเป็น Y เสมอ"

2.2. การจัดการข้อมูลซ้ำซ้อน (Duplicate Handling)

16	31	Female	58000	Bachelor	7	10000	7.5	Blue
17	25	Male	35000	Bachelor	2	10000	7.5	Blue
18	25	Male	35000	Bachelor	2	10000	7.5	Blue
19	25	Male	35000	Bachelor	2	10000	7.5	Blue
20	33	Male	62000	Bachelor	9	15000	6.5	Green


ความซ้ำซ้อนของข้อมูล (Data Redundancy) มักเกิดจากการรวมไฟล์ข้อมูลจากหลายแหล่ง หรือข้อผิดพลาดในการบันทึกซ้ำ ในทาง Machine Learning การมีข้อมูลซ้ำจะทำให้โมเดลเกิดความลำเอียง (Bias) โดยให้ความสำคัญกับแพทเทิร์นที่ซ้ำกันนั้นมากเกินไปจนเกินความเป็นจริง และอาจทำให้การวัดผลความแม่นยำ (Accuracy) ผิดเพี้ยนหากข้อมูลซ้ำไปปรากฏทั้งในชุด Training และ Testing แนวทางปฏิบัติให้กำจัดแถวที่ข้อมูลซ้ำกัน ให้เหลือเพียงข้อมูลที่เป็นเอกลักษณ์ (Unique Record) เท่านั้น

2.3. การจัดการข้อมูลผิดปกติ (Outlier Detection and Treatment)

1	Age	Gender	Income	Education	Work_Exp	Debt_Amo	Sleep_Hou	Favorite_Color
2	25	Male	35000	Bachelor	2	10000	7.5	Blue
3	32	Female	55000	Master	6	5000	6	Red
4	-5	Male	0	None	-1	0	2	Unknown
5	45	Male	85000	PhD	15	0	6.5	Blue

ข้อมูลผิดปกติ (Outliers) คือจุดข้อมูลที่มีค่าแตกต่างจากข้อมูลส่วนใหญ่อย่างมีนัยสำคัญ ซึ่งอาจเกิดจากความผิดพลาด (เช่น อายุ -5 ปี) หรือเป็นเหตุการณ์พิเศษที่เกิดขึ้นจริง (เช่น รายได้ระดับมหาเศรษฐี) การมีอยู่ของ Outlier สามารถบิดเบือนค่าเฉลี่ยและส่งผลกระทบบ่อยอย่างรุนแรงต่อโมเดลที่อ่อนไหวต่อระยะทาง เช่น Linear Regression หรือ KNN


2.3.1. การตรวจจับ Outlier ด้วย Z-Score Method (คะแนนมาตรฐาน) ใช้วัดว่าข้อมูลนั้นอยู่ห่างจากค่าเฉลี่ย (μ) เป็นระยะกี่เท่าของส่วนเบี่ยงเบนมาตรฐาน (σ) ตามสูตร $Z = \frac{x-\mu}{\sigma}$ หาก $|Z| > 3$ (เกิน 3 เท่าของส่วนเบี่ยงเบนมาตรฐาน) มักถือว่าเป็น Outlier ภายใต้สมมติฐานการแจกแจงปกติ



2.3.2. การตรวจจับ Outlier ด้วย Interquartile Range (IQR) Method เป็นวิธีที่อาศัยควอร์ไทล์ (Quartiles) ซึ่งทนทานต่อ Outlier มากกว่า Z-Score คำนวณระยะห่างระหว่างควอร์ไทล์ที่ 3(Q3) และควอร์ไทล์ที่ 1(Q1): $IQR = Q3 - Q1$ โดยจะกำหนดขอบเขต (Fences) ของข้อมูลและข้อมูลที่อยู่นอกเหนือขอบเขตถือเป็น Outlier

2.3.2.1. ขอบเขตล่าง (Lower Bound) = $Q1 - 1.5 \times IQR$

2.3.2.2. ขอบเขตบน (Upper Bound) = $Q3 + 1.5 \times IQR$




3. การแปลงสภาพข้อมูล (Data Transformation) และการปรับสเกล (Feature Scaling)

หลังจากผ่านขั้นตอนการทำความสะอาด ข้อมูลอาจมีความถูกต้องครบถ้วน แต่ยังไม่ "พร้อม" ในทางคณิตศาสตร์ ปัญหาสำคัญที่มักพบคือ "ความแตกต่างของมาตราส่วน" (Scale Discrepancy) ระหว่างตัวแปร ซึ่งเป็นอุปสรรคสำคัญในการเข้าสู่คำตอบของอัลกอริทึม

3.1. ปัญหาเรื่องสเกลในมุมมองของ Machine Learning

พิจารณาชุดข้อมูลที่มีตัวแปร "อายุ" (ช่วง 20-60 ปี) และ "รายได้" (ช่วง 15,000-100,000 บาท) หากป้อนข้อมูลดิบนี้เข้าสู่โมเดล อัลกอริทึมที่คำนวณโดยใช้ระยะทางแบบยูคลิด (Euclidean Distance) เช่น KNN จะถูกครอบงำโดยตัวแปร "รายได้" หนักขึ้น เนื่องจากผลต่างของตัวเลขหลักหมื่นย่อมส่งผลต่อระยะทางรวมมากกว่าผลต่างของตัวเลขหลักสิบ ทั้งที่ในความเป็นจริง อายุอาจเป็นปัจจัยที่มีนัยสำคัญเท่ากันหรือมากกว่า นอกจากนี้ ในอัลกอริทึมที่ใช้ Gradient Descent เพื่อหาค่าต่ำสุดของฟังก์ชันความสูญเสีย (Loss Function) ข้อมูลที่ไม่ได้ปรับสเกลจะทำให้รูปทรงของ Error Surface มีลักษณะรีขาง (Elongated) ส่งผลให้การเข้าสู่จุดต่ำสุดทำได้ช้าและไม่มีประสิทธิภาพ

3.2. การทำ Normalization (Min-Max Scaling)



Normalization คือกระบวนการแปลงข้อมูลเชิงเส้นเพื่อบีบอัดช่วงของข้อมูลให้อยู่ในขอบเขตที่กำหนด โดยทั่วไปคือช่วง

$$X_{\text{scaled}} = \frac{X_i - X_{\text{min}}}{X_{\text{max}} - X_{\text{min}}}$$


โดยที่ X_i คือข้อมูลเดิม, X_{min} คือค่าน้อยที่สุดในฟีเจอร์, และ X_{max} คือค่ามากที่สุด

3.2.1. การวิเคราะห์เชิงลึกและการประยุกต์ใช้

3.2.1.1. บริบทการใช้งาน: วิธีนี้เหมาะสมอย่างยิ่งเมื่อเราทราบขอบเขตที่แน่นอนของข้อมูล (Bounded Data) เช่น ข้อมูลพิกเซลรูปภาพ (0-255) หรือคะแนนสอบ (0-100) และเหมาะสำหรับอัลกอริทึมที่ต้องการข้อมูลนำเข้าในช่วง 0-1 เช่น Neural Networks (เพื่อให้สอดคล้องกับ Activation Functions) หรือ KNN

3.2.1.2. จุดอ่อน (Sensitivity to Outliers): เนื่องจากสมการใช้ค่า X_{min} และ X_{max} เป็นตัวหาร หากมี Outlier ที่มีค่าสูงโดดผิดปกติ (เช่น รายได้ 100 ล้านบาท ในขณะที่คนส่วนใหญ่อยู่ที่ 3 หมื่นบาท) ค่า X_{max} จะสูงมาก ส่งผลให้ข้อมูลส่วนใหญ่ถูกบีบอัดไปกองรวมกันที่ค่าใกล้ 0 (เช่น 0.0003) ทำให้สูญเสียความละเอียดในการจำแนกความแตกต่างระหว่างข้อมูลปกติ

3.3. การทำ Standardization (Z-Score Scaling)



Standardization เป็นเทคนิคที่เปลี่ยนการกระจายตัวของข้อมูลให้มีคุณสมบัติของ การแจกแจงปกติมาตรฐาน (Standard Normal Distribution) โดยมีค่าเฉลี่ย (μ) เท่ากับ 0 และส่วนเบี่ยงเบนมาตรฐาน (σ) เท่ากับ 1

$$x_{\text{std}} = \frac{x - \mu}{\sigma}$$

3.3.1. บริบทการใช้งาน: เป็นวิธีมาตรฐานสำหรับโมเดลที่ตั้งสมมติฐานว่าข้อมูลมีการแจกแจงแบบปกติ (Gaussian Assumption) เช่น Linear Regression, Logistic Regression และ Support Vector Machines (SVM) รวมถึงเทคนิคการลดมิติข้อมูลอย่าง Principal Component Analysis (PCA) ที่ต้องการให้ฟีเจอร์มีความแปรปรวน (Variance) เทียบเคียงกัน

3.3.2. ความทนทาน (Robustness): Standardization ทนทานต่อ Outlier ได้ดีกว่า Normalization เนื่องจากไม่ได้ถูกกำหนดขอบเขตด้วยค่าสูงสุด/ต่ำสุด แต่ใช้ค่าเฉลี่ยและส่วนเบี่ยงเบนมาตรฐานเป็นตัวอ้างอิง ข้อมูลที่เป็น Outlier จะยังคงปรากฏเป็นค่าที่สูงหรือต่ำกว่าปกติ (เช่น +5 หรือ -4) แต่จะไม่บีบอัดข้อมูลส่วนใหญ่จนเสียรูปทรงการกระจายตัว

3.4. ตารางเปรียบเทียบ: Normalization vs Standardization

ประเด็นเปรียบเทียบ	NORMALIZATION (MIN-MAX)	STANDARDIZATION (Z-SCORE)
ช่วงของข้อมูล (RANGE)	ถูกบีบให้อยู่ในช่วง เสมอ	ไม่จำกัดช่วง (Unbounded) ส่วนใหญ่อยู่ในช่วง [-3, +3]
ผลกระทบจาก OUTLIER	สูงมาก (ข้อมูลปกติจะถูกบีบจนแยกยาก)	ต่ำกว่า (ข้อมูลยังคงรักษารูปทรงการกระจายตัวเดิม)
การใช้งานที่เหมาะสม	Image Processing, Neural Networks, KNN	Linear Regression, Logistic Regression, SVM, PCA
สถิติพื้นฐานที่ใช้	ค่าต่ำสุด (Min) และ ค่าสูงสุด (Max)	ค่าเฉลี่ย (Mean) และ ส่วนเบี่ยงเบนมาตรฐาน (SD)
ผลลัพธ์การกระจายตัว	ไม่เปลี่ยนรูปทรงการแจกแจงเดิม	เปลี่ยนศูนย์กลางไปที่ 0 และปรับ SD เป็น 1

4. วิศวกรรมคุณลักษณะ (Feature Engineering)

Feature Engineering คือศิลปะของการแปลงข้อมูลดิบให้เป็นตัวแปร (Features) ที่สามารถสื่อสารความหมายต่อโมเดล Machine Learning ได้ดีที่สุด เป็นขั้นตอนที่ต้องอาศัยความคิดสร้างสรรค์และความเข้าใจในข้อมูลอย่างลึกซึ้ง เพื่อให้ AI สามารถ "มองเห็น" รูปแบบที่ซ่อนอยู่ได้

4.1. การแปลงข้อมูลหมวดหมู่ (Encoding Categorical Data)

โมเดลทางคณิตศาสตร์ไม่สามารถทำความเข้าใจข้อมูลที่เป็นข้อความ (String) หรือหมวดหมู่ (Category) เช่น "เพศชาย", "ระดับปริญญาตรี" หรือ "สีแดง" ได้โดยตรง จึงจำเป็นต้องแปลงข้อมูลเหล่านี้ให้อยู่ในรูปของตัวเลข (Numerical Representation)

4.1.1. Label Encoding (การเข้ารหัสแบบลำดับ)

วิธีนี้ทำการจับคู่แต่ละหมวดหมู่กับตัวเลขจำนวนเต็ม (Integer) เช่น:

- ประถมศึกษา → 0
- มัธยมศึกษา → 1
- ปริญญาตรี → 2
- ปริญญาโท → 3

4.1.1.1. ทฤษฎีและการใช้งาน: วิธีนี้เหมาะสมที่สุดสำหรับ ข้อมูลที่มีลำดับ (Ordinal Data) ซึ่งมีความสัมพันธ์เชิงเปรียบเทียบขึ้นกว่าหรือขั้นสุด (Greater than/Less than) อย่างชัดเจน เช่น ระดับการศึกษา หรือ ระดับความพึงพอใจ โมเดลสามารถเรียนรู้ได้ว่า $3 > 2 > 1$ ซึ่งสะท้อนความจริงของข้อมูล

4.1.1.2. ข้อผิดพลาดที่พบบ่อย: การนำ Label Encoding ไปใช้กับ ข้อมูลที่ไม่มีลำดับ (Nominal Data) เช่น สี หรือ ชื่อประเทศ หากเรากำหนดให้ ไทย=0, ญี่ปุ่น=1, สหรัฐ=2 โมเดลทางคณิตศาสตร์ (เช่น Linear Regression) จะตีความผิดๆ ว่า "สหรัฐ" มีค่ามากกว่า "ไทย" หรือ "ญี่ปุ่น" คือค่าเฉลี่ยของไทยและสหรัฐ ซึ่งเป็นตรรกะที่ผิดเพี้ยนและส่งผลเสียต่อความแม่นยำ

4.2. One-Hot Encoding (การเข้ารหัสแบบวัน-ฮอต)

เพื่อแก้ปัญหการสร้างความสัมพันธ์ปลอมๆ ในข้อมูล Nominal Data เทคนิค One-Hot Encoding จะทำการสร้างคอลัมน์ใหม่ (Dummy Variables) สำหรับแต่ละหมวดหมู่ โดยใช้ค่า 0 และ 1 ในการระบุสถานะ

ตัวอย่าง: ตัวแปร "สี" (แดง, เขียว, น้ำเงิน)

ข้อมูลเดิม (สี)	คอลัมน์ 1	คอลัมน์ 2	คอลัมน์ 3
แดง	1	0	0
เขียว	0	1	0
น้ำเงิน	0	0	1

4.2.1. ทฤษฎีและการใช้งาน: วิธีนี้สร้างเวกเตอร์ที่ตั้งฉากกัน (Orthogonal Vectors) ในปริภูมิหลายมิติ ทำให้ระยะห่างระหว่างแต่ละหมวดหมู่มีความเท่าเทียมกัน ไม่มีสีใดมาก่อนหรือหลัง เหมาะสำหรับ ข้อมูล Nominal Data

4.2.2. ข้อจำกัด (Curse of Dimensionality): ข้อเสียร้ายแรงของวิธีนี้คือการเพิ่มจำนวนมิติของข้อมูล หากตัวแปรต้นทางมีจำนวนหมวดหมู่มาก (High Cardinality) เช่น รหัสไปรษณีย์ 10,000 รหัส จะทำให้เกิดคอลัมน์ใหม่ 10,000 คอลัมน์ ส่งผลให้ข้อมูลมีความเบาบาง (Sparse Matrix) สิ้นเปลืองหน่วยความจำ และทำให้โมเดลเสี่ยงต่อภาวะ Overfitting

4.3. การคัดเลือกคุณลักษณะ (Feature Selection)

"ข้อมูลมาก" ไม่ได้แปลว่า "ดี" เสมอไป ในชุดข้อมูลมักมีตัวแปรที่ไม่เกี่ยวข้อง (Irrelevant) หรือตัวแปรที่เป็นขยะ (Noise) ปะปนอยู่ การคัดเลือก Feature คือกระบวนการกรองเอาเฉพาะตัวแปรที่มีความสำคัญต่อการทำนายจริงๆ เพื่อลดความซับซ้อนของโมเดลและเพิ่มความเร็วในการประมวลผล

4.3.1. Filter Methods: เป็นการคัดเลือกโดยใช้ค่าทางสถิติเป็นตัวตัดสิน โดยไม่ขึ้นกับอัลกอริทึมที่จะใช้เรียนรู้ เช่น การหาค่าสหสัมพันธ์ (Correlation Coefficient) ระหว่าง Feature กับ Target หากค่าเข้าใกล้ 0 แสดงว่าไม่มีความสัมพันธ์กัน ก็ควรตัดทิ้ง หรือการใช้ Chi-Square Test สำหรับข้อมูล Categorical

4.3.2. Wrapper Methods: ใช้วิธีการ "ลองผิดลองถูก" โดยสร้างโมเดลหลายๆ รอบด้วยชุด Feature ที่แตกต่างกัน แล้วดูว่าชุดไหนให้ประสิทธิภาพสูงสุด (เช่น Recursive Feature Elimination - RFE) วิธีนี้ให้ผลลัพธ์แม่นยำแต่ใช้ทรัพยากรการคำนวณสูงมาก

4.3.3. Embedded Methods: การคัดเลือกเกิดขึ้นโดยอัตโนมัติในระหว่างกระบวนการเรียนรู้ของโมเดล เช่น Lasso Regression (L1 Regularization) ซึ่งมีคุณสมบัติทางคณิตศาสตร์ในการบีบสัมประสิทธิ์ของตัวแปรที่ไม่สำคัญให้กลายเป็นศูนย์ (Zero Coefficients) หรือการใช้ Feature Importance จากโมเดลตระกูล Decision Trees

5. การแบ่งชุดข้อมูล (Data Splitting)

ขั้นตอนสุดท้ายและมีความสำคัญยิ่งยวดในการเตรียมข้อมูลคือการแบ่งข้อมูล (Split Data) เพื่อเตรียมพร้อมสำหรับการฝึกสอนและการประเมินผล วัตถุประสงค์หลักคือเพื่อจำลองสถานการณ์การใช้งานจริง และป้องกันปัญหา Overfitting

5.1. แนวคิดการแยก Train-Test

5.1.1. Training Set (ชุดข้อมูลฝึกสอน): เปรียบเสมือน "แบบฝึกหัด" ที่ครูมอบให้นักเรียนทำในห้องเรียน เพื่อให้ AI ได้เรียนรู้แพทเทิร์นและความสัมพันธ์ระหว่างตัวแปร X (Features) และ y (Target)

5.1.2. Testing Set (ชุดข้อมูลทดสอบ): เปรียบเสมือน "ข้อสอบปลายภาค" ที่นักเรียนไม่เคยเห็นมาก่อน ใช้เพื่อวัดความสามารถในการนำความรู้ไปประยุกต์ใช้กับโจทย์ใหม่ (Generalization) หาก AI ทำคะแนนแบบฝึกหัดได้ดีมากแต่ตกม้าตายในข้อสอบจริง แสดงว่า AI เกิดการ "ท่องจำ" (Overfitting) แทนที่จะ "เข้าใจ"

5.2. สัดส่วนและกฎของพาเรโต (The 80/20 Rule)

Train	Test
80%	20%

สัดส่วนมาตรฐานที่นิยมใช้และได้รับการยอมรับในวงการคือ 80:20 (Training 80%, Testing 20%) ซึ่งสอดคล้องกับหลักการพาเรโต (Pareto Principle) ที่เชื่อว่าผลลัพธ์ส่วนใหญ่มาจากการกระทำส่วนน้อย แต่ในบริบทของ Machine Learning การมีข้อมูลฝึกสอนจำนวนมาก (80%) จะช่วยให้โมเดลจับสัญญาณ (Signal) ได้ชัดเจน ในขณะที่ข้อมูลทดสอบ 20% ก็ยังมีความเพียงพอในทางสถิติที่จะให้ผลการประเมินที่น่าเชื่อถือ อย่างไรก็ตาม ในกรณีที่ชุดข้อมูลมีขนาดใหญ่มาก (เช่น หลักล้านแถว) สัดส่วนอาจปรับเป็น 90:10 หรือ 99:1 ได้ตามความเหมาะสม

5.3. การแบ่งแบบ Stratified Sampling

ในชุดข้อมูลจริง เรามักพบปัญหาความไม่สมดุลของข้อมูล (Imbalanced Data) เช่น ในโจทย์ทำนายรายได้ อาจมีคนรวยเพียง 10% และคนรายได้ปานกลาง 90% หากใช้การสุ่มแบ่งแบบปกติ (Random Split) มีความเสี่ยงที่ข้อมูลคนรวยทั้งหมดจะไปกองอยู่ใน Training Set และไม่มีเลยใน Testing Set ทำให้เราไม่สามารถวัดผลความแม่นยำในการทำนายคนรวยได้เลย

Stratification (การแบ่งแบบชั้นภูมิ) คือเทคนิคที่เข้ามาแก้ปัญหานี้ โดยในฟังก์ชัน `train_test_split` ของ Scikit-learn สามารถกำหนดพารามิเตอร์ `stratify=y` เพื่อบังคับให้สัดส่วนของคลาสใน Training Set และ Testing Set เหมือนกับสัดส่วนในข้อมูลต้นฉบับทุกประการ (เช่น มีคนรวย 10% ทั้งใน Train และ Test) ช่วยลดความลำเอียงในการวัดผลได้อย่างมีนัยสำคัญ

5.4. ความสามารถในการทำซ้ำ (Reproducibility)

ในการทดลองทางวิทยาศาสตร์ ผลลัพธ์ต้องสามารถทำซ้ำได้ (Reproducible) การกำหนดค่า `random_state` (หรือ Seed) ในการแบ่งข้อมูล ช่วยให้คอมพิวเตอร์ใช้วิธีการสุ่มแบบเดิมทุกครั้งที่เรารันโค้ด ทำให้มั่นใจได้ว่าความเปลี่ยนแปลงของประสิทธิภาพโมเดลเกิดจากการปรับจูนอัลกอริทึม ไม่ใช่เกิดจากโชคในการสุ่มข้อมูล

อ้างอิง

Ahmed, N. (2023, July 11). The motivation for train-test split. *Medium*.

<https://medium.com/@nahmed3536/the-motivation-for-train-test-split-2b1837f596c3>

Amorim, L. B. V., Cavalcanti, G. D. C., & Cruz, R. M. O. (2022). *The choice of scaling technique matters for classification performance*. arXiv. <https://arxiv.org/abs/2212.12343>

Analytics Vidhya. (2016, December 1). *Introduction to feature selection methods with an example (or how to select the right variables)*.

<https://www.analyticsvidhya.com/blog/2016/12/introduction-to-feature-selection-methods-with-an-example-or-how-to-select-the-right-variables/>

Analytics Vidhya. (2020, April 7). *Feature scaling for machine learning: Understanding the difference between normalization vs. standardization*.

<https://www.analyticsvidhya.com/blog/2020/04/feature-scaling-machine-learning-normalization-standardization/>

Analytics Vidhya. (2020, March 9). *One Hot Encoding vs. Label Encoding using Scikit-Learn*.

<https://www.analyticsvidhya.com/blog/2020/03/one-hot-encoding-vs-label-encoding-using-scikit-learn/>

Bhat, A. (2023, October 4). Day 33: Feature selection techniques (Filter, Wrapper and Embedded Methods). *Medium*. <https://medium.com/@bhatadithya54764118/day-33-feature-selection-techniques-filter-wrapper-and-embedded-methods-00fb2bd04aa3>

Biased Algorithms. (2020, May 27). One-Hot Encoding vs. Label Encoding. *Medium*.

<https://medium.com/biased-algorithms/one-hot-encoding-vs-label-encoding-28aee12b3984>

Built In. (n.d.). *Train-test split*. <https://builtin.com/data-science/train-test-split>

Business Analytics Institute. (n.d.). *Detecting and treating outliers with z-scores and IQR*.

<https://businessanalyticsinstitute.com/detecting-and-treating-outliers-with-z-scores-and-iqr/>

Codefinity. (n.d.). *Feature selection techniques in machine learning*.

<https://codefinity.com/blog/Feature-Selection-Techniques-in-Machine-Learning>

DataCamp. (n.d.). *Normalization vs standardization*.

<https://www.datacamp.com/tutorial/normalization-vs-standardization>

Domo. (2023, August 8). *The best AI starts with clean data: A step-by-step guide*.

<https://www.domo.com/blog/the-best-ai-starts-with-clean-data-step-by-step-guide>

Feature selection. (2024, June 2). In *Wikipedia*.

https://en.wikipedia.org/wiki/Feature_selection

GeeksforGeeks. (n.d.). *Difference between One Hot Encoding and Label Encoding*.

<https://www.geeksforgeeks.org/machine-learning/one-hot-encoding-vs-label-encoding/>

GeeksforGeeks. (n.d.). *What is data imputation?* <https://www.geeksforgeeks.org/machine-learning/what-is-data-imputation/>

GeeksforGeeks. (n.d.). *Z-score in statistics*. <https://www.geeksforgeeks.org/data-science/z-score-in-statistics/>

Great Learning. (n.d.). *Data normalization and standardization*.

<https://www.mygreatlearning.com/blog/data-normalization-and-standardization/>

Improvado. (n.d.). *What is data preparation?* <https://improvado.io/blog/what-is-data-preparation>

Imputation (statistics). (2024, May 22). In *Wikipedia*.

[https://en.wikipedia.org/wiki/Imputation_\(statistics\)](https://en.wikipedia.org/wiki/Imputation_(statistics))

Insightsoftware. (2023, May 4). *How to handle missing data values while data cleaning*.

<https://insightsoftware.com/blog/how-to-handle-missing-data-values-while-data-cleaning/>

Kang, H. (2013). The prevention and handling of the missing data. *Korean Journal of*

Anesthesiology, 64(5), 402–406. <https://pmc.ncbi.nlm.nih.gov/articles/PMC3668100/>

Masters in Data Science. (n.d.). *How to deal with missing data*.

<https://www.mastersindatascience.org/learning/how-to-deal-with-missing-data/>

Mike. (n.d.). *Imputation missing data*. In *Data analysis*. Bookdown.

https://bookdown.org/mike/data_analysis/imputation-missing-data.html

- MITSDE. (2022, November 11). *Data imputation techniques: Handling missing data in machine learning*. <https://blog.mitsde.com/data-imputation-techniques-handling-missing-data-in-machine-learning/>
- Mukherjee, A. (2020, December 2). Why do we use stratify in train_test_split. *Medium*. <https://medium.com/@aymuosmukherjee/why-do-we-use-stratify-in-train-test-split-e3eb296a5494>
- Multimodal. (n.d.). *How to prepare data for AI*. <https://www.multimodal.dev/post/how-to-prepare-data-for-ai>
- Pennsylvania State University. (n.d.). *Lesson 3: Data description*. STAT 200: Elementary Statistics. <https://online.stat.psu.edu/stat200/lesson/3/3.2>
- Procogia. (n.d.). *Interquartile range method for reliable data analysis*. <https://procogia.com/interquartile-range-method-for-reliable-data-analysis/>
- Raschka, S. (n.d.). *Feature selection categories*. https://sebastianraschka.com/faq/docs/feature_sele_categories.html
- SandTech. (n.d.). *5 steps to prepare your data for AI*. <https://www.sandtech.com/insight/5-steps-to-prepare-your-data-for-ai/>
- Scikit-learn. (n.d.). *Compare the effect of different scalers on data with outliers*. https://scikit-learn.org/stable/auto_examples/preprocessing/plot_all_scaling.html
- Scikit-learn. (n.d.). *sklearn.model_selection.train_test_split*. https://scikit-learn.org/stable/modules/generated/sklearn.model_selection.train_test_split.html
- Shepperd, M. (n.d.). *Cleaning data*. In *Modern data analysis for software engineering*. Bookdown. https://bookdown.org/martin_shepperd/ModernDataBook/C5_Cleaning.html
- Softnix. (2020, February 25). *Anomaly detections part 2: การหา anomaly ด้วย boxplots*. <https://www.softnix.co.th/2020/02/25/anomaly-detections-part-2-การหา-anomaly-ด้วย-boxplots/>

Stack Exchange (Data Science). (2016). *Min-max scaling more sensitive to outliers than simple feature scaling?*

<https://datascience.stackexchange.com/questions/128116/min-max-scaling-more-sensitive-to-outliers-than-simple-feature-scaling>

Stack Exchange (Data Science). (2017). *Statistics: Train and test data split.*

<https://datascience.stackexchange.com/questions/17328/statistics-train-and-test-data-split>

Stack Overflow. (2022). *Difference between one hot encoding and label encoding of target output label.* <https://stackoverflow.com/questions/73271013/difference-between-one-hot-encoding-and-label-encoding-of-target-output-label>

Statology. (n.d.). *Label Encoding vs. One-Hot Encoding.* <https://www.statology.org/label-encoding-vs-one-hot-encoding/>

Tableau. (n.d.). *What is data cleaning?* <https://www.tableau.com/learn/articles/what-is-data-cleaning>

TarangDS. (2020, June 25). KNN imputation: The complete guide. *Medium*.

<https://medium.com/@tarangds/knn-imputation-the-complete-guide-146f932870a7>

TarangDS. (2020, June 25). Normalization vs standardization: Understanding the key differences and when to use them. *Medium*.

<https://medium.com/@tarangds/normalization-vs-standardization-understanding-the-key-differences-and-when-to-use-them-5f6953017a04>

The Data Monk. (n.d.). *Missing value treatment.* <https://thedatamonk.com/missing-value-treatment/>

Towards AI. (n.d.). *Data scaling 101: StandardScaler vs MinMaxScaler.*

<https://pub.towardsai.net/data-scaling-101-standardscaler-vs-minmaxscaler-e8f78d77283f>

Towards Data Science. (n.d.). *3 simple statistical methods for outlier detection.*

<https://towardsdatascience.com/3-simple-statistical-methods-for-outlier-detection-db762e86cd9d/>

Train in Data. (n.d.). *Feature selection with embedded methods*.

<https://www.blog.trainindata.com/feature-selection-with-embedded-methods/>

TrainInData. (n.d.). *MeanMedianImputer*. Feature-engine. [https://feature-](https://feature-engine.trainindata.com/en/1.8.x/user_guide/imputation/MeanMedianImputer.html)

[engine.trainindata.com/en/1.8.x/user_guide/imputation/MeanMedianImputer.html](https://feature-engine.trainindata.com/en/1.8.x/user_guide/imputation/MeanMedianImputer.html)

University of Texas at El Paso. (n.d.). *Technical report* [CS Tech Report 1209]. ScholarWorks.

https://scholarworks.utep.edu/cs_techrep/1209/