


ใบความรู้ที่ 4 การเรียนรู้แบบมีผู้สอน

1. ปรัชญาและทฤษฎีรากฐานของการเรียนรู้แบบมีผู้สอน (Supervised Learning)

1.1. นิยามและกลไกการทำงานเชิงลึก



การเรียนรู้แบบมีผู้สอน หรือ Supervised Learning ถือเป็นกระบวนทัศน์หลัก (Paradigm) ของปัญญาประดิษฐ์ในยุคปัจจุบัน ซึ่งมีรากฐานมาจากการเลียนแบบกระบวนการเรียนรู้ของมนุษย์ (Cognitive Modeling) นิยามที่ชัดเจนที่สุดของ Supervised Learning คือ กระบวนการสร้างฟังก์ชันทางคณิตศาสตร์ที่สามารถจับคู่ "ข้อมูลนำเข้า" (Input Variables / Features) กับ "ข้อมูลผลลัพธ์" (Output Variables / Targets) โดยอาศัยตัวอย่างที่ผ่านการ "ติดฉลาก" (Labeled Data) มาแล้วจำนวนมาก

ในเชิงเปรียบเทียบเพื่อให้เห็นภาพตามหลักการ Andragogy (การเรียนรู้ของผู้ใหญ่) ที่เน้นการเชื่อมโยงกับประสบการณ์เดิม 1 กระบวนการนี้เปรียบเสมือนการสอนเด็กเล็กด้วย "บัตรคำศัพท์" (Flashcards) เมื่อผู้สอน (Supervisor) ชูรูปภาพสัตว์ (Input: X) และระบุชื่อสัตว์นั้นอย่างชัดเจน (Label: Y) เช่น "นี่คือแมว" หรือ "นี่คือสุนัข" สมอของเด็กรจะทำการสังเกตแพทเทิร์นหรือคุณลักษณะเด่น (Features) ของภาพนั้น เช่น รูปร่างหู ลักษณะหนวด หรือรูปทรงของจมูก แล้วเชื่อมโยงเข้ากับคำตอบที่ได้รับ การกระทำซ้ำ ๆ (Iteration) ด้วยตัวอย่างที่หลากหลายจะช่วยให้สมองสร้างกฎเกณฑ์ภายใน (Internal Rules) ขึ้นมา จนกระทั่งเมื่อเด็กไปพบเจอแมวตัวใหม่ที่ไม่เคยเห็นมาก่อนในชีวิต ก็สามารถระบุได้ถูกต้องว่าเป็น "แมว" โดยอาศัยกฎเกณฑ์ที่เรียนรู้มา

ในทางคณิตศาสตร์และวิทยาการคอมพิวเตอร์ เป้าหมายสูงสุดของ Supervised Learning คือการประมาณค่าฟังก์ชัน f ที่สามารถอธิบายความสัมพันธ์ระหว่างตัวแปร X และ Y ภายใต้สมการ:

$$Y = f(X) + \epsilon$$

โดยที่ ϵ (Epsilon) คือค่าความคลาดเคลื่อนที่ลดทอนไม่ได้ (Irreducible Error) ซึ่งอาจเกิดจากสัญญาณรบกวนในข้อมูล (Noise) หรือความซับซ้อนของระบบที่ไม่สามารถอธิบายได้ด้วยตัวแปรที่มีอยู่ 4 กระบวนการ "เรียนรู้" (Learning) หรือ "การฝึกฝน" (Training) จึงหมายถึงการปรับจูนพารามิเตอร์ภายในของอัลกอริทึมเพื่อให้ฟังก์ชัน $f(X)$ ให้ผลลัพธ์ที่ใกล้เคียงกับค่าจริง Y มากที่สุด หรือกล่าวอีกนัยหนึ่งคือ การลดขนาดของ Error ให้เหลือน้อยที่สุดนั่นเอง


1.2. บทบาทของข้อมูล: Ground Truth และการติดฉลาก

ความสำเร็จของ Supervised Learning ขึ้นอยู่กับคุณภาพของข้อมูลเป็นสำคัญ ข้อมูลที่มีฉลาก (Labeled Data) ทำหน้าที่เป็น "ความจริงภาคพื้น" หรือ Ground Truth ซึ่งเป็นมาตรฐานที่ใช้ในการตรวจสอบความถูกต้องของการทำนาย หากข้อมูล Ground Truth มีความผิดพลาด หรือมีการติดฉลากที่ไม่สม่ำเสมอ (Inconsistent Labeling) โมเดล AI ก็จะเรียนรู้ความผิดพลาดนั้นไปด้วย ซึ่งเป็นปรากฏการณ์ที่เรียกว่า "Garbage In, Garbage Out"

การติดฉลากข้อมูลในโจทย์ระดับสูงอาจต้องอาศัยผู้เชี่ยวชาญเฉพาะทาง เช่น การระบุตำแหน่งก้อนเนื้อในภาพถ่ายทางการแพทย์ หรือการจำแนกอารมณ์จากข้อความ ซึ่งต้องใช้ต้นทุนและเวลาสูง นี่จึงเป็นข้อจำกัดสำคัญประการหนึ่งของ Supervised Learning เมื่อเทียบกับแนวทางอื่น ๆ เช่น Unsupervised Learning

1.3. การจำแนกประเภทงาน: Regression vs. Classification

การทำความเข้าใจความแตกต่างระหว่างงานประเภท "การถดถอย" (Regression) และ "การจำแนกประเภท" (Classification) เป็นจุดเริ่มต้นที่สำคัญที่สุดในการเลือกใช้อัลกอริทึมที่เหมาะสม สามารถจำแนกความแตกต่างได้ดังนี้



1.3.1. การถดถอย (Regression)

งานประเภท Regression เกี่ยวข้องกับการทำนายผลลัพธ์ที่เป็น "ตัวเลขต่อเนื่อง" (Continuous Value/Quantitative Data) ซึ่งมีคุณสมบัติทางคณิตศาสตร์คือ สามารถวัดค่าได้ เปรียบเทียบมากกว่า-น้อยกว่าได้ และมีความละเอียดเป็นทศนิยมได้ไม่จำกัด

ลักษณะเด่นคือผลลัพธ์มีความต่อเนื่อง (Infinite possibilities within a range)

ตัวอย่างเชิงลึก:

1.3.1.1. การพยากรณ์ทางอุตุนิยมวิทยา: การทำนายอุณหภูมิ (เช่น 29.78°C), ปริมาณน้ำฝน (มิลลิเมตร), หรือความเร็วลม ตัวเลขเหล่านี้มีการเปลี่ยนแปลงอย่างต่อเนื่องและสิ้นไหล

1.3.1.2. การวิเคราะห์ทางการเงิน: การคาดการณ์ราคาหุ้น, ราคาทองคำ, หรืออัตราแลกเปลี่ยน ซึ่งมีความผันผวนเป็นตัวเลขทศนิยม

1.3.1.3. การแพทย์: การทำนายระดับน้ำตาลในเลือด, ความดันโลหิต, หรือระยะเวลาที่คาดว่าจะรอดชีวิตของผู้ป่วย

อัลกอริทึมที่นิยมได้แก่ Linear Regression, Polynomial Regression, Ridge/Lasso Regression, Support Vector Regression (SVR)

1.3.2. การจำแนกประเภท (Classification)

งานประเภท Classification เกี่ยวข้องกับการทำนายผลลัพธ์ที่เป็น "กลุ่ม" หรือ "หมวดหมู่" (Categorical/Discrete Value) หรือข้อมูลเชิงคุณภาพ (Qualitative Data) ซึ่งมีขอบเขตของคำตอบที่ชัดเจนและจำกัด (Finite Set) ไม่สามารถวัดค่าเป็นตัวเลขต่อเนื่องได้

ลักษณะเด่นผลลัพธ์เป็นป้ายกำกับ (Label) หรือคลาส (Class) ที่แยกจากกันโดยเด็ดขาด (Mutually Exclusive)

ประเภทย่อย:

1.3.2.1. Binary Classification: มีคำตอบเพียง 2 ทางเลือก เช่น ใช่/ไม่ใช่, ป่วย/ไม่ป่วย, ผ่าน/ไม่ผ่าน, สเปม/ไม่สเปม

1.3.2.2. Multi-class Classification: มีคำตอบมากกว่า 2 ทางเลือก เช่น การจำแนกสายพันธุ์สัตว์ (แมว/หมา/นก), การตัดเกรด (A/B/C/D/F)

ตัวอย่างเชิงลึก:

1.3.2.3. การประมวลผลภาพ (Computer Vision): การระบุว่าวัตถุในภาพคืออะไร

1.3.2.4. การวิเคราะห์ความเสี่ยง (Risk Scoring): การตัดสินใจอนุมัติหรือไม่อนุมัติสินเชื่อ (โดยผลลัพธ์คือ อนุมัติ/ไม่อนุมัติ)

1.3.2.5. การวินิจฉัยโรค: การระบุว่าเนื้องอกเป็นชนิด "Benign" (ไม่ร้ายแรง) หรือ "Malignant" (ร้ายแรง)

อัลกอริทึมที่นิยม: Logistic Regression (แม้ชื่อเป็น Regression แต่ใช้สำหรับ Classification), Decision Tree, Random Forest, Support Vector Machine (SVM), Naive Bayes


ตารางที่ 1: การเปรียบเทียบเชิงลึกระหว่าง Regression และ Classification

มิติการเปรียบเทียบ	REGRESSION (การถดถอย)	CLASSIFICATION (การจำแนกประเภท)
ประเภทของตัวแปรตาม (TARGET)	ต่อเนื่อง (Continuous) เชิงปริมาณ	ไม่ต่อเนื่อง (Discrete) เชิงคุณภาพ
ลักษณะของผลลัพธ์	ค่าตัวเลขที่วัดระดับได้	ป้ายกำกับ, คลาส, หรือความน่าจะเป็นของคลาส
เป้าหมายของโมเดล	หาเส้นฟังก์ชันที่ฟิตกับจุดข้อมูล (Best Fit Line/Curve)	หาเส้นแบ่งเขตข้อมูล (Decision Boundary)
การวัดผลความผิดพลาด	ระยะห่างระหว่างค่าจริงกับค่าทำนาย (Error Metric)	ความถูกต้องของการจัดกลุ่ม (Accuracy Metric)
ตัวชี้วัดประสิทธิภาพ (METRICS)	MAE, MSE, RMSE, $R^2 score$	Accuracy, Precision, Recall, F1-Score, AUC-ROC
ตัวอย่าง	ราคาบ้าน = 3.5 ล้านบาท	ลูกค้าจะซื้อสินค้าหรือไม่ = ใช่ (1)

2. ทฤษฎีคณิตศาสตร์และการทำงานของ Linear Regression

Linear Regression หรือ การถดถอยเชิงเส้น เป็นอัลกอริทึมพื้นฐานที่มีบทบาทสำคัญอย่างยิ่งในการปูพื้นฐานความเข้าใจด้าน Machine Learning แม้จะเป็นโมเดลที่ดูเรียบง่าย แต่หลักการของมันถูกนำไปประยุกต์ใช้ในโมเดลที่ซับซ้อนกว่าอย่าง Neural Networks และ Deep Learning

2.1. โครงสร้างทางคณิตศาสตร์ของ Linear Regression



แนวคิดหลักของ Linear Regression คือการค้นหความสัมพันธ์เชิงเส้น (Linear Relationship) ระหว่างตัวแปรต้น (x) และตัวแปรตาม (y) โดยสมมติว่าการเปลี่ยนแปลงของ y สามารถอธิบายได้ด้วยการเปลี่ยนแปลงของ x ในอัตราส่วนที่คงที่ 13 สมการพื้นฐานที่เราคุ้นเคยจากคณิตศาสตร์ระดับมัธยมปลายคือ:

$$y = mx + C$$

อย่างไรก็ตาม ในบริบทของ Machine Learning เราจะใช้สัญลักษณ์ที่แตกต่างออกไปเพื่อรองรับการขยายขนาดสู่หลายตัวแปร (Multivariate) และสอดคล้องกับพารามิเตอร์ที่โมเดลต้องเรียนรู้:

$$\hat{y} = w_1x_1 + w_2x_2 + \dots + w_nx_n + b$$

หรือเขียนในรูปสัญกรณ์เวกเตอร์ (Vector Notation) ได้ว่า:

$$\hat{y} = w^T x + b$$

องค์ประกอบสำคัญของสมการ:

2.1.1. $\hat{y}$ (y-hat): คือค่าพยากรณ์ที่โมเดลคำนวณได้


2.1.2. x_i (Features): คือค่าของตัวแปรต้นตัวที่ i (เช่น อุณหภูมิสูงสุด, ปริมาณฝน)

2.1.3. w_i (Weights): หรือ **ค่าน้ำหนัก** เทียบเท่ากับความชัน (m) ในสมการเส้นตรง ค่าน้ำหนักบ่งบอกถึง "อิทธิพล" หรือ "ความสำคัญ" ของตัวแปร x นั้น ๆ ที่มีต่อผลลัพธ์ หาก w มีค่ามาก แสดงว่าการเปลี่ยนแปลงของ x เพียงเล็กน้อยจะส่งผลกระทบต่อ y อย่างมาก หาก w เป็นลบ แสดงว่ามีความสัมพันธ์แบบผกผัน

2.1.4. b (Bias): หรือ **ค่าไบแอส** เทียบเท่ากับจุดตัดแกน $y(c)$ เป็นค่าพื้นฐานของโมเดล เมื่อตัวแปรต้นทั้งหมดเป็นศูนย์ (Baseline) ค่า Bias ช่วยให้เส้นกราฟสามารถเลื่อนขึ้นลงได้เพื่อให้สอดคล้องกับข้อมูลจริงมากที่สุด โดยไม่ได้ถูกตรึงไว้ที่จุดกำเนิด (0,0)

2.2. การหาเส้นที่ดีที่สุด: Ordinary Least Squares (OLS)

หัวใจสำคัญของการ "เทรน" (Training) โมเดล Linear Regression คือการค้นหาค่า W และ b ที่ดีที่สุด ซึ่งจะทำให้เส้นกราฟที่วาดขึ้นมามีความใกล้เคียงกับจุดข้อมูลจริงทุกจุดมากที่สุด วิธีการทางสถิติมาตรฐานที่ใช้ในการแก้ปัญหานี้เรียกว่า Ordinary Least Squares (OLS)



หลักการของ OLS คือการ **ลดผลรวมของความคลาดเคลื่อนยกกำลังสอง (Minimize Sum of Squared Errors: SSE)** ให้เหลือน้อยที่สุด ความคลาดเคลื่อน หรือ Residual (e) คือระยะห่างในแนวตั้งระหว่างจุดข้อมูลจริง (y) กับเส้นที่โมเดลทำนาย ($\hat{y}$) :

$$e_i = y_i - \hat{y}_i$$

$$CostFunction(J) = \sum_{i=1}^n (y_i - \hat{y}_i)^2$$

ทำไมต้องยกกำลังสอง?

2.2.1. ขจัดปัญหาเครื่องหมาย: ความคลาดเคลื่อนมีทั้งค่าบวก (ทำนายต่ำไป) และค่าลบ (ทำนายสูงไป) หากนำมารวมกันตรง ๆ ค่าอาจจะหักล้างกันจนกลายเป็นศูนย์ ทำให้เข้าใจผิดว่าโมเดลแม่นยำ การยกกำลังสองทำให้ค่าทั้งหมดเป็นบวก

2.2.2. การลงโทษ (Penalization): ฟังก์ชันยกกำลังสองจะให้ค่าความเสียหายสูงมากเมื่อความคลาดเคลื่อนมีขนาดใหญ่ (เช่น $2^2=4$ แต่ $10^2=100$) ซึ่งเป็นการบังคับให้โมเดลพยายามลดความผิดพลาดที่รุนแรงให้ได้มากที่สุด และดึงเส้นกราฟให้ครอบคลุมจุดข้อมูลที่กระจายตัว (Outliers) ได้ดีขึ้น

2.3. ข้อสมมติฐานทางสถิติ (Assumptions of Linear Regression)

ในการนำ Linear Regression ไปใช้งานจริงเพื่อให้ได้ผลลัพธ์ที่เชื่อถือได้ทางสถิติ ข้อมูลควรสอดคล้องกับข้อสมมติฐาน 4 ประการ (Linear Regression Assumptions) ซึ่งเป็นความรู้เชิงลึกที่นักวิเคราะห์ข้อมูลควรทราบ :

2.3.1. Linearity (ความเป็นเส้นตรง): ความสัมพันธ์ระหว่างตัวแปรต้นและตัวแปรตามต้องมีความเป็นเชิงเส้น หากข้อมูลมีความโค้ง (เช่น กราฟพาราโบลา) การใช้ Linear Regression จะทำให้เกิดความผิดพลาดสูง (High Bias / Underfitting)

2.3.2. Independence (ความเป็นอิสระ): ข้อมูลแต่ละตัวอย่าง (Observation) ต้องเป็นอิสระต่อกัน ไม่ควรมีความสัมพันธ์กันเอง (Autocorrelation) ปัญหานี้มักพบในข้อมูลอนุกรมเวลา (Time Series) ซึ่งค่าของวันนี้อาจขึ้นอยู่กับเมื่อวาน

2.3.3. Homoscedasticity (ความแปรปรวนคงที่): ความแปรปรวนของความคลาดเคลื่อน (Residuals) ควรมีค่าคงที่ตลอดช่วงของข้อมูล ไม่ควรมีลักษณะเป็นรูปกรวย (Heteroscedasticity) ที่ช่วงต้นเกาะกลุ่มกันดีแต่ช่วงปลายกระจายตัวกว้าง

2.3.4. Normality of Errors (การแจกแจงปกติของความคลาดเคลื่อน): หากนำค่าความคลาดเคลื่อนทั้งหมดมาพลอตกราฟ ควรได้กราฟระฆังคว่ำ (Normal Distribution) ซึ่งแสดงว่าโมเดลมีความสมดุล ไม่มีความเอนเอียงไปทางใดทางหนึ่ง

3. วิศวกรรมข้อมูลและการเตรียมความพร้อม (Data Engineering Pipeline)

ขั้นตอนที่สำคัญและใช้เวลามากที่สุดคือ การเตรียมข้อมูล (Data Preparation) ซึ่งเป็นรากฐานสำคัญตามหลักการ "Garbage In, Garbage Out"

3.1. การทำความสะอาดและจัดการข้อมูล (Data Cleaning)

ไฟล์ข้อมูลในโลกความเป็นจริงมักมีความสกปรก (Dirty Data) และไม่สมบูรณ์ ขั้นตอนการจัดการที่จำเป็นประกอบด้วย:

3.1.1. การจัดการหน่วยความจำ (Memory Management): การโหลดไฟล์ขนาดใหญ่ด้วย Pandas ควรใช้พารามิเตอร์ `low_memory=False` เพื่อป้องกันคำเตือนเกี่ยวกับการเดาประเภทข้อมูล (Dtype Guessing) ซึ่งอาจทำให้เกิดความผิดพลาดในการจัดการหน่วยความจำของคอมพิวเตอร์

3.1.2. การคัดเลือกคุณลักษณะ (Feature Selection): ข้อมูลดิบอาจมีคอลัมน์จำนวนมากที่ไม่เกี่ยวข้อง การเลือกเฉพาะคอลัมน์ที่มีอิทธิพลต่อการทำนาย (เช่น MaxTemp, MinTemp, Precip, MeanTemp) ช่วยลดความซับซ้อนของโมเดล (Model Complexity) และลดความเสี่ยงของการเกิด Overfitting

3.1.3. การจัดการข้อมูลผิดปกติ (Handling Non-numeric/Error Data): ข้อมูลจริงอาจมีข้อความหรืออักขระแปลกปลอมปะปนในช่องตัวเลข การใช้ฟังก์ชัน `pd.to_numeric(..., errors='coerce')` จะช่วยบังคับแปลงข้อมูลให้เป็นตัวเลข และเปลี่ยนค่าที่แปลงไม่ได้ให้กลายเป็น NaN (Not a Number) เพื่อป้องกันไม่ให้โปรแกรมหยุดทำงาน (Crash) ระหว่างการคำนวณทางคณิตศาสตร์

3.1.4. การจัดการค่าสูญหาย (Handling Missing Values): เมื่อข้อมูลเกิดช่องว่าง (NaN) เราต้องตัดสินใจว่าจะจัดการอย่างไร

3.1.4.1. การลบ (Dropping): ใช้คำสั่ง `dropna()` วิธีนี้ง่ายและรวดเร็ว เหมาะสำหรับกรณีที่ข้อมูลมีจำนวนมหาศาลและส่วนที่หายไปมีสัดส่วนน้อย (เช่น ใน EP 9 ข้อมูลหายไปเพียงเล็กน้อยจากแสนกว่าแถว)

3.1.4.2. การแทนที่ (Imputation): ในกรณีที่ข้อมูลมีน้อย การลบทิ้งอาจทำให้เสียข้อมูลสำคัญ อาจใช้วิธีแทนที่ด้วยค่าเฉลี่ย (Mean), มัธยฐาน (Median), หรือใช้โมเดลอื่นมาทำนายค่าที่หายไป

3.2. วิศวกรรมคุณลักษณะสำหรับข้อมูลอนุกรมเวลา (Feature Engineering for Time Series)

โจทย์ "การพยากรณ์อากาศวันพรุ่งนี้" เป็นโจทย์ประเภทอนุกรมเวลา (Time Series) ซึ่งข้อมูลมีการเรียงลำดับตามเวลา การจะใช้ Linear Regression ซึ่งเป็นโมเดลที่มองข้อมูลเป็นจุดอิสระ (Independent) จำเป็นต้องมีเทคนิคการแปลงข้อมูล:

3.2.1. Lag Features (การสร้างฟีเจอร์ย้อนหลัง/ล่วงหน้า): คือการสร้างคอลัมน์เป้าหมาย (NextMeanTemp) โดยการเลื่อน (Shift) ข้อมูล MeanTemp ขึ้นมา 1 บรรทัดด้วยคำสั่ง `.shift(-1)` ผลลัพธ์: ในแถวข้อมูลของ "วันนี้" (Row t) จะประกอบด้วยฟีเจอร์ของวันนี้ (X_t) และมีเฉลยเป็นอุณหภูมิของ "พรุ่งนี้" (Y_{t+1}) อยู่ในบรรทัดเดียวกัน ทำให้โมเดลสามารถเรียนรู้ความสัมพันธ์แบบ $x_t \rightarrow Y_{t+1}$ ได้เหมือนข้อมูลปกติ

3.2.2. การจัดการ Multicollinearity: ข้อควรระวังสำคัญที่ระบุในบทเรียนคือ ไม่ควรนำ MeanTemp ของวันนี้มารวมใน Input Features (X) หากเรามี MaxTemp และ MinTemp อยู่แล้ว เพราะค่าเฉลี่ยคำนวณมาจากค่าสูงสุดและต่ำสุดโดยตรง การใส่ตัวแปรที่มีความสัมพันธ์กันเองสูง (Multicollinearity) เข้าไป จะทำให้โมเดลสับสนในการให้ค่าน้ำหนัก และอาจทำให้ผลการทำนายกว้างได้

3.3. การแบ่งชุดข้อมูล (Train/Test Split Strategy)

กระบวนการแบ่งข้อมูลเป็นขั้นตอนมาตรฐานที่ขาดไม่ได้ โดยทั่วไปจะแบ่งเป็น Training Set และ Test Set (ในสัดส่วน 80:20 หรือ 70:30)

3.3.1. Training Set (80%): ใช้สำหรับให้โมเดลเรียนรู้ ปรับจูนค่าน้ำหนัก (W) และไบแอส (b) เพื่อลดค่า Error

3.3.2. Test Set (20%): ทำหน้าที่เป็น "ข้อสอบลับ" (Unseen Data) ที่โมเดลไม่เคยเห็นมาก่อน ใช้เพื่อวัดความสามารถในการ "วางนัยทั่วไป" (Generalization) ว่าโมเดลสามารถนำความรู้ไปใช้กับสถานการณ์จริงได้ดีแค่ไหน

3.3.3. Random State: การกำหนดค่า `random_state` (เช่น 0 หรือ 42) ในการแบ่งข้อมูลมีความสำคัญต่อความสามารถในการทำซ้ำ (Reproducibility) เพื่อให้แน่ใจว่าผลการทดลองจะคงที่ทุกครั้งที่รันโปรแกรม ไม่เปลี่ยนแปลงไปตามการสุ่มแต่ละรอบ

4. การวัดผลและประเมินประสิทธิภาพ (Evaluation Metrics)

ในงาน Regression เราไม่สามารถวัดผลด้วยความแม่นยำ (Accuracy) เป็นเปอร์เซ็นต์ความถูกต้องได้ เหมือนงาน Classification (เช่น ทายถูก 90 จาก 100 รูป) เนื่องจากผลลัพธ์เป็นตัวเลขต่อเนื่อง เราจึงต้องวัด "ระยะห่าง" หรือ "ระดับความคลาดเคลื่อน" แทน โดยใช้ตัวชี้วัดหลัก 3 ตัว ดังนี้ :

4.1. Mean Absolute Error (MAE)

4.1.1. สูตรทางคณิตศาสตร์:

$$MAE = \frac{1}{n} \sum_{i=1}^n |y_i - \hat{y}_i|$$

4.1.2. คำอธิบาย: คือ "ค่าเฉลี่ยของความคลาดเคลื่อนสัมบูรณ์" เป็นการนำผลต่างระหว่างค่าจริงและค่าพยากรณ์มาหาค่าสัมบูรณ์ (Absolute) แล้วเฉลี่ยกัน

4.1.3. การตีความ: ค่า MAE จะมีหน่วยเดียวกับข้อมูล (เช่น องศาเซลเซียส) บอกเราตรง ๆ ว่า "โดยเฉลี่ยแล้ว โมเดลทายผิดไปกี่หน่วย" คำนี้น่าเข้าใจง่ายและมีความเป็นธรรมชาติ (Robust) ต่อข้อมูลที่ผิดปกติ (Outliers) ในระดับหนึ่ง

4.1.4. ตัวอย่างในบทเรียน: $MAE = 1.11^{\circ}\text{C}$ หมายความว่า โดยเฉลี่ยโมเดลทายอุณหภูมิคลาดเคลื่อนไปบวกลบประมาณ 1 องศา

4.2. Root Mean Squared Error (RMSE)

4.2.1. สูตรทางคณิตศาสตร์:

$$RMSE = \sqrt{\frac{1}{n} \sum_{j=1}^n (y_i - \hat{y}_i)^2}$$

4.2.2. คำอธิบาย: คือ "รากที่สองของค่าเฉลี่ยความคลาดเคลื่อนยกกำลังสอง"

4.2.3. การตีความ: มีหน่วยเดียวกับข้อมูลเช่นกัน แต่ค่ามักจะสูงกว่าหรือเท่ากับ MAE เสมอ

4.2.4. จุดเด่นเชิงวิเคราะห์: RMSE มีความไวต่อความผิดพลาดขนาดใหญ่ (Large Errors) มากกว่า MAE เพราะขั้นตอนการยกกำลังสองจะขยายขนาดของความผิดพลาดที่สูงให้ยิ่งสูงขึ้นไปอีก (เช่น Error=10 เมื่อยกกำลังสองจะเป็น 100 ในขณะที่ Error=1 ยังคงเป็น 1) ดังนั้น หากค่า RMSE สูงกว่า MAE มาก ๆ แสดงว่าโมเดลมีความไม่เสถียร (Variance High) คือทายถูกเป็นส่วนใหญ่แต่มีบางครั้งที่ทายผิดพลาดอย่างรุนแรง

4.3. R-Squared (R^2 Score)

4.3.1. สูตรทางคณิตศาสตร์:

$$R^2 = 1 - \frac{\sum (y_i - \hat{y}_i)^2}{\sum (y_i - \bar{y})^2}$$

4.3.2. คำอธิบาย: หรือ "สัมประสิทธิ์การตัดสินใจ" (Coefficient of Determination) เป็นการเปรียบเทียบความผิดพลาดของโมเดลเรา ($\hat{y}$) กับความผิดพลาดของโมเดลพื้นฐานที่ทายด้วยค่าเฉลี่ย ($\bar{y}$)

4.3.3. การตีความ: เป็นค่าสัดส่วนที่ไม่มีหน่วย มีค่าสูงสุดคือ 1.0 (หรือ 100%)

4.3.3.1. $R^2 \approx 1$: โมเดลมีความสามารถสูงมาก ตัวแปรต้น (x) สามารถอธิบายความผันแปรของตัวแปรตาม (y) ได้เกือบทั้งหมด

4.3.3.2. $R^2 \approx 0$: โมเดลไม่ดีกว่าการเดาด้วยค่าเฉลี่ย (Mean)

4.3.3.3. $R^2 < 0$: โมเดลแย่กว่าการเดาด้วยค่าเฉลี่ย (อาจเกิดจากข้อมูลไม่มีความสัมพันธ์กันเลย หรือเลือกโมเดลผิดประเภท)


4.3.4. ตัวอย่างในบทเรียน: $R^2 = 0.942$ (94.2%) แสดงว่าตัวแปรสภาพอากาศวันนี้ (สูงสุด/ต่ำสุด/ฝน) มีอิทธิพลอย่างมากและสามารถใช้อธิบายอุณหภูมิของวันพรุ่งนี้ได้อย่างแม่นยำ

ตารางที่ 2: การเลือกใช้ Metrics ในสถานการณ์ต่าง ๆ

สถานการณ์	ควรใช้ METRIC ไດ?	เหตุผล
ต้องการอธิบายให้คนทั่วไปเข้าใจง่าย	MAE	แปลความหมายได้ตรงตัว (เช่น ผิดไปกี่บาท, กี่องศา)
ต้องการโมเดลที่ห้ามผิดพลาดรุนแรง (เช่น การแพทย์, ความปลอดภัย)	RMSE	ลงโทษ (Penalize) ความผิดพลาดสูง ๆ อย่างหนัก เพื่อบีบให้โมเดลระวัง Outliers
ต้องการเปรียบเทียบว่าโมเดล "เก่ง" แค่ไหนในเชิงสถิติ	R^2	บอกสัดส่วนความสัมพันธ์ได้ดี ไม่ขึ้นกับหน่วยของข้อมูล

5. แนวคิดขั้นสูงและการแก้ปัญหา (Advanced Concepts & Troubleshooting)

เพื่อให้ผู้เรียนมีความเข้าใจที่ลึกซึ้งและสามารถนำความรู้ไปประยุกต์ใช้ได้อย่างยืดหยุ่น จำเป็นต้องเข้าใจปัญหาคลาสสิก 2 ประการที่นักพัฒนา AI ทุกคนต้องเจอ คือ Overfitting และ Underfitting ซึ่งเกี่ยวข้องกับทฤษฎี Bias-Variance Tradeoff



5.1. Overfitting (การเรียนรู้เกินพอดี / High Variance)

5.1.1. อาการ: เปรียบเสมือนนักเรียนที่ "ท่องจำข้อสอบ" อย่างแม่นยำ ทำคะแนนสอบเก็บคะแนนในห้องเรียน (Training Set) ได้เต็มหรือเกือบเต็ม แต่พอไปสอบจริงหรือเจอโจทย์ประยุกต์ (Test Set) กลับทำไม่ได้เลย ความแม่นยำตกวบ

5.1.2. สาเหตุ: โมเดลมีความซับซ้อนมากเกินไป (Too Complex) จนพยายามเรียนรู้ทุกจุดข้อมูล รวมถึง "สัญญาณรบกวน" (Noise) หรือรายละเอียดปลีกย่อยที่ไม่ใช่สาระสำคัญ ทำให้โมเดลสร้างกฎที่จำเพาะเจาะจงเกินไปจนไม่สามารถนำไปใช้กับข้อมูลอื่นได้

5.1.3. แนวทางแก้ไข:

5.1.3.1. เพิ่มข้อมูล (More Data): ให้โมเดลเห็นตัวอย่างที่หลากหลายขึ้น

5.1.3.2. ลดความซับซ้อน (Simplify Model): ตัดฟีเจอร์ที่ไม่จำเป็นออก (Feature Selection) หรือลดระดับของสมการ (เช่น จาก Polynomial เป็น Linear)

5.1.3.3. Regularization: เทคนิคทางคณิตศาสตร์ (L1/L2) เพื่อลงโทษค่าน้ำหนัก (sw) ที่สูงเกินไป (จะมีการกล่าวถึงในบทเรียนขั้นสูง)

5.2. Underfitting (การเรียนรู้ไม่เพียงพอ / High Bias)

5.2.1. อาการ: เปรียบเสมือนนักเรียนที่ "เรียนไม่รู้เรื่อง" หรือ "ทำการบ้านไม่ได้" โมเดลทำผลงานได้แย่ทั้งใน Training Set และ Test Set (ค่า Error สูงทั้งคู่)

5.2.2. สาเหตุ: โมเดลมีความซับซ้อนน้อยเกินไป (Too Simple) ไม่สามารถจับรูปแบบความสัมพันธ์ที่ซับซ้อนของข้อมูลได้ เช่น ข้อมูลมีความโค้งเป็นรูปตัว U แต่เราพยายามใช้เส้นตรง (Linear) ไปลากผ่าน ทำให้ไม่ว่าจะลากอย่างไรก็ไม่สามารถเข้าใกล้จุดข้อมูลส่วนใหญ่ได้

5.2.3. แนวทางแก้ไข:

5.2.3.1. เพิ่มความซับซ้อน (Increase Complexity): เปลี่ยนไปใช้โมเดลที่มีความยืดหยุ่นสูงขึ้น (เช่น Decision Tree, Neural Network)

5.2.3.2. เพิ่มฟีเจอร์ (Feature Engineering): หาข้อมูลนำเข้าใหม่ ๆ ที่มีความสัมพันธ์กับผลลัพธ์มากขึ้น

5.2.3.3. ลดการทำ Regularization: ปลดปล่อยให้โมเดลมีอิสระในการเรียนรู้มากขึ้น

ภาพจำ (Mental Model): เป้าหมายของการสร้าง AI คือการหาจุดสมดุล (Sweet Spot) ระหว่าง Bias และ Variance ซึ่งเป็นจุดที่กราฟ Error ของ Test Set มีค่าต่ำที่สุด ก่อนที่มันจะเริ่มดีดตัวสูงขึ้นสวนทางกับ Training Error

6. การประยุกต์ใช้จริงและบทสรุป (Practical Application & Conclusion)

6.1. การนำโมเดลไปใช้งาน (Deployment)

6.1.1. Persistence: การใช้ `joblib.dump` ช่วยให้เราสามารถ "บันทึกสถานะสมอง" ของ AI (ค่า w และ b ที่ดีที่สุด) เก็บไว้เป็นไฟล์ (.pkl) เปรียบเสมือนการเซฟเกม ทำให้ไม่ต้องเสียเวลาเทรนใหม่ทุกครั้งที่จะใช้งาน

6.1.2. Inference: การใช้ `joblib.load` เพื่อเรียกคืนโมเดลและนำมาทำนายข้อมูลชุดใหม่ (New Data) เช่น การจำลองสถานการณ์ "วันแดดร้อน" หรือ "วันฝนตก" ผลลัพธ์ที่ได้จากการทดลองในวิดีโอแสดงให้เห็นว่าโมเดลสามารถให้คำตอบที่สมเหตุสมผลตามตรรกะของมนุษย์ (วันร้อน $\rightarrow$ อุณหภูมิพุ่งนี้สูง, วันหนาว $\rightarrow$ อุณหภูมิพุ่งนี้ต่ำ) ซึ่งยืนยันว่าคณิตศาสตร์ Linear Regression สามารถจับรูปแบบความสัมพันธ์ของธรรมชาติได้จริง

6.2. บทสรุปและก้าวต่อไป

หน่วยการเรียนรู้นี้ได้ทำหน้าที่เชื่อมโยงสะพานระหว่าง "ทฤษฎี" และ "การปฏิบัติ" อย่างสมบูรณ์ ผู้เรียนได้รับความรู้ตั้งแต่รากฐานของ Supervised Learning ความแตกต่างของงาน AI ประเภทต่าง ๆ กลไกคณิตศาสตร์เบื้องหลัง Linear Regression ไปจนถึงกระบวนการทางวิศวกรรมข้อมูลที่ใช้สำหรับการสร้างโมเดลที่มีคุณภาพ

องค์ความรู้เรื่องการแบ่งข้อมูล (Train/Test Split), การวัดผลด้วย RMSE/MAE, และความเข้าใจเรื่อง Overfitting/Underfitting ในบทนี้ จะเป็น "เครื่องมือทางความคิด" (Cognitive Tools) ที่สำคัญอย่างยิ่งเมื่อผู้เรียนก้าวเข้าสู่เนื้อหาที่ซับซ้อนขึ้นในบทถัดไป เช่น Neural Networks และ Deep Learning ซึ่งแม้จะมีโครงสร้างที่ซับซ้อนกว่า แต่ก็ยังคงวางอยู่บนรากฐานของแนวคิดเหล่านี้ทั้งสิ้น

อ้างอิง

365 Data Science. (2021, November 10). *OLS assumptions*.

<https://365datascience.com/tutorials/statistics-tutorials/ols-assumptions/>

Abdulazeez, F. (2023, June 17). Essential regression evaluation metrics: MSE, RMSE, MAE, R^2 , and adjusted R^2 . *Medium*. <https://farshadabdulazeez.medium.com/essential-regression-evaluation-metrics-mse-rmse-mae-r%C2%B2-and-adjusted-r%C2%B2-0600daa1c03a>

Amazon Web Services. (n.d.). *Model fit: Underfitting vs. overfitting*.

<https://docs.aws.amazon.com/machine-learning/latest/dg/model-fit-underfitting-vs-overfitting.html>

Analytics Vidhya. (2020, June 29). Elucidating bias-variance, under-fitting and over-fitting.

Medium. <https://medium.com/analytics-vidhya/elucidating-bias-variance-under-fitting-and-over-fitting-273846621622>

Analytics Vidhya. (2021, July 5). MAE, MSE, RMSE, coefficient of determination, adjusted R-squared — Which metric is better? *Medium*. <https://medium.com/analytics-vidhya/mae-mse-rmse-coefficient-of-determination-adjusted-r-squared-which-metric-is-better-cd0326a5697e>

Cetin, R. K. (2020, August 24). The importance of splitting datasets into training, validation and test sets. *Medium*. <https://ruveydakardelcetin.medium.com/the-importance-of-splitting-datasets-into-training-validation-and-test-sets-417caaeae91d>

Clarity. (n.d.). *R² & RMSE*. <https://click.clarity.io/knowledge/r2-rmse>

Clemson University. (n.d.). *Regression*. Department of Physics and Astronomy.

<https://science.clemson.edu/physics/labs/tutorials/regression/index.html>

Codecademy. (n.d.). *Regression vs. classification*.

<https://www.codecademy.com/article/regression-vs-classification>

CodeSignal. (n.d.). *Understanding MSE, MAE, RMSE, and their differences*.

<https://codesignal.com/learn/courses/deep-dive-into-regression-and-classification-metrics/lessons/understanding-mse-mae-rmse-and-their-differences>

DataCamp. (n.d.). *OLS regression in R and Python*. <https://www.datacamp.com/tutorial/ols-regression>

DeepLearning.AI Community. (2023, July). *Can someone explain what weights and biases are?* [Online forum post]. <https://community.deeplearning.ai/t/can-someone-explain-what-weights-and-biases-are/394280>

Exxact Corp. (2020, March 18). *Overfitting, generalization, the bias-variance tradeoff*. <https://www.exxactcorp.com/blog/deep-learning/overfitting-generalization-the-bias-variance-tradeoff>

Flitto DataLab. (2023, April 18). *What is underfitting and overfitting? Easy example*. <https://datalab.flitto.com/en/company/blog/what-is-underfitting-and-overfitting-easy-example/>

Frost, J. (n.d.). *OLS linear regression assumptions*. Statistics By Jim. <https://statisticsbyjim.com/regression/ols-linear-regression-assumptions/>

GeeksforGeeks. (n.d.). *ML | Classification vs. regression*. <https://www.geeksforgeeks.org/machine-learning/ml-classification-vs-regression/>

GeeksforGeeks. (n.d.). *Supervised machine learning*. <https://www.geeksforgeeks.org/machine-learning/supervised-machine-learning/>

Google Cloud. (n.d.). *What is supervised learning?* <https://cloud.google.com/discover/what-is-supervised-learning>

Google Developers. (n.d.). *Linear regression*. Machine Learning Crash Course. <https://developers.google.com/machine-learning/crash-course/linear-regression?hl=th>

Gultekin, H. (2020, November 23). *Classification vs regression*. Medium. <https://medium.com/@hazallgultekin/classification-vs-regression-e15c619604f7>

Hex. (n.d.). *Detecting and remedying multicollinearity*. <https://hex.tech/blog/detecting-and-remedying-multicollinearity/>

IBM. (n.d.). *Classification vs. regression*. <https://www.ibm.com/think/topics/classification-vs-regression>

IBM. (n.d.). *Multicollinearity*. <https://www.ibm.com/think/topics/multicollinearity>

IBM. (n.d.). *Overfitting vs. underfitting*. <https://www.ibm.com/think/topics/overfitting-vs-underfitting>

IBM. (n.d.). *What is supervised learning?* <https://www.ibm.com/think/topics/supervised-learning>

Manoj, M. (2020, June 1). Assumptions of linear regression clearly explained. *Medium*. <https://medium.com/@mangammanoj/assumptions-of-linear-regression-clearly-explained-1935984c7208>

ML Cheatsheet. (n.d.). *Linear regression*. ReadTheDocs. https://ml-cheatsheet.readthedocs.io/en/latest/linear_regression.html

Ordinary least squares. (2024, May 15). In *Wikipedia*. https://en.wikipedia.org/wiki/Ordinary_least_squares

Patel, D. (2020, March 18). Linear regression. *Medium*. <https://deeppatel23.medium.com/linear-regression-9a8d3b141b6b>

Sabbha, M. (2023, August 3). Understanding MAE, MSE, and RMSE: Key metrics in machine learning. *Dev.to*. https://dev.to/mondal_sabbha/understanding-mae-mse-and-rmse-key-metrics-in-machine-learning-4la2

Sharma, D. (2019, August 5). Step by step machine learning: Linear regression. *Medium*. <https://medium.com/@deek.sha.rma/step-by-step-machine-learning-linear-regression-712eb215d52f>

Srivastava, S. (2023, July 15). Evaluating model performance: Understanding MAE, MSE, RMSE, and R^2 score. *Medium*. <https://medium.com/@srivastavashivansh8922/evaluating-model-performance-understanding-mae-mse-rmse-and-r%C2%B2-score-5516e10fe8d6>

Supervised learning. (2024, June 2). In *Wikipedia*. https://en.wikipedia.org/wiki/Supervised_learning

Towards Data Science. (2019, September 24). What are RMSE and MAE? *Medium*. <https://towardsdatascience.com/what-are-rmse-and-mae-e405ce230383/>

Udacity. (2025, February). *Regression vs. classification: Key differences and when to use each*. <https://www.udacity.com/blog/2025/02/regression-vs-classification-key-differences-and-when-to-use-each.html>

Venkatesh, S. (2023, October 16). Underfitting vs overfitting with visualization. *Medium*.
<https://medium.com/@shrinath.venkatesh/underfitting-vs-overfitting-with-visualization-891b5c686a8b>

XLSTAT. (n.d.). *Ordinary least squares regression (OLS)*.
<https://www.xlstat.com/solutions/features/ordinary-least-squares-regression-ols>