


ใบความรู้ที่ 4 การเรียนรู้แบบมีผู้สอน

วัตถุประสงค์การเรียนรู้

1. รู้จักแนวคิดพื้นฐานของการเรียนรู้แบบมีผู้สอน (Supervised Learning) และความสำคัญของข้อมูลที่มีฉลาก (Labeled Data)
2. เข้าใจความแตกต่างระหว่างงานประเภทการถดถอย (Regression) และการจำแนกประเภท (Classification) พร้อมกรณีตัวอย่างในชีวิตจริง
3. รู้จักหลักการทำงานของโมเดลการถดถอยเชิงเส้น (Linear Regression)
4. เข้าใจขั้นตอนการวิศวกรรมข้อมูล (Data Engineering) ทั้งการทำความสะอาด การจัดการค่าว่าง และการเตรียมข้อมูลให้พร้อมสำหรับโมเดล
5. รู้จักสาเหตุของปัญหาการเรียนรู้เกินพอดี (Overfitting) และความจำเป็นในการใช้ชุดข้อมูลทดสอบ (Test Set) เป็น "ข้อสอบลับ"
6. เข้าใจหลักเกณฑ์การประเมินประสิทธิภาพโมเดลด้วยค่า MAE, RMSE และ R^2 Score
7. รู้จักวิธีบันทึกและโหลดโมเดล (Model Persistence) เพื่อนำ AI ไปประยุกต์ใช้งานจริง

1. ปรัชญาและทฤษฎีรากฐานของการเรียนรู้แบบมีผู้สอน (Supervised Learning)

1.1. นิยามและกลไกการทำงานเชิงลึก



การเรียนรู้แบบมีผู้สอน หรือ Supervised Learning ถือเป็นกระบวนทัศน์หลัก (Paradigm) ของปัญญาประดิษฐ์ในยุคปัจจุบัน ซึ่งมีรากฐานมาจากการเลียนแบบกระบวนการเรียนรู้ของมนุษย์ (Cognitive Modeling) นิยามที่ชัดเจนที่สุดของ Supervised Learning คือ กระบวนการสร้างฟังก์ชันทางคณิตศาสตร์ที่สามารถจับคู่ "ข้อมูลนำเข้า" (Input Variables / Features) กับ "ข้อมูลผลลัพธ์" (Output Variables / Targets) โดยอาศัยตัวอย่างที่ผ่านการ "ติดฉลาก" (Labeled Data) มาแล้วจำนวนมาก

ในเชิงเปรียบเทียบเพื่อให้เห็นภาพตามหลักการ Andragogy (การเรียนรู้ของผู้ใหญ่) ที่เน้นการเชื่อมโยงกับประสบการณ์เดิม 1 กระบวนการนี้เปรียบเสมือนการสอนเด็กเล็กด้วย "บัตรคำศัพท์" (Flashcards) เมื่อผู้สอน (Supervisor) ชูรูปภาพสัตว์ (Input: X) และระบุชื่อสัตว์นั้นอย่างชัดเจน (Label: Y) เช่น "นี่คือแมว" หรือ "นี่คือสุนัข" สมอของเด็กรจะทำการสังเกตแพทเทิร์นหรือคุณลักษณะเด่น (Features) ของภาพนั้น เช่น รูปร่างหู ลักษณะหนวด หรือรูปทรงของจมูก แล้วเชื่อมโยงเข้ากับคำตอบที่ได้รับ การกระทำซ้ำ ๆ (Iteration) ด้วยตัวอย่างที่หลากหลายจะช่วยให้สมองสร้างกฎเกณฑ์ภายใน (Internal Rules) ขึ้นมาจนกระทั่งเมื่อเด็กไปพบเจอแมวตัวใหม่ที่ไม่เคยเห็นมาก่อนในชีวิต ก็สามารถระบุได้ถูกต้องว่าเป็น "แมว" โดยอาศัยกฎเกณฑ์ที่เรียนรู้มา

ในทางคณิตศาสตร์และวิทยาการคอมพิวเตอร์ เป้าหมายสูงสุดของ Supervised Learning คือการประมาณค่าฟังก์ชัน f ที่สามารถอธิบายความสัมพันธ์ระหว่างตัวแปร X และ Y ภายใต้สมการ:

$$Y = f(X) + \epsilon$$

โดยที่ ϵ (Epsilon) คือค่าความคลาดเคลื่อนที่ลดทอนไม่ได้ (Irreducible Error) ซึ่งอาจเกิดจากสัญญาณรบกวนในข้อมูล (Noise) หรือความซับซ้อนของระบบที่ไม่สามารถอธิบายได้ด้วยตัวแปรที่มีอยู่ 4 กระบวนการ "เรียนรู้" (Learning) หรือ "การฝึกฝน" (Training) จึงหมายถึงการปรับจูนพารามิเตอร์ภายในของอัลกอริทึมเพื่อให้ฟังก์ชัน $f(X)$ ให้ผลลัพธ์ที่ใกล้เคียงกับค่าจริง Y มากที่สุด หรือกล่าวอีกนัยหนึ่งคือ การลดขนาดของ Error ให้เหลือน้อยที่สุดนั่นเอง


1.2. บทบาทของข้อมูล: Ground Truth และการติดฉลาก

ความสำเร็จของ Supervised Learning ขึ้นอยู่กับคุณภาพของข้อมูลเป็นสำคัญ ข้อมูลที่มีฉลาก (Labeled Data) ทำหน้าที่เป็น "ความจริงภาคพื้น" หรือ Ground Truth ซึ่งเป็นมาตรฐานที่ใช้ในการตรวจสอบความถูกต้องของการทำนาย หากข้อมูล Ground Truth มีความผิดพลาด หรือมีการติดฉลากที่ไม่สม่ำเสมอ (Inconsistent Labeling) โมเดล AI ก็จะเรียนรู้ความผิดพลาดนั้นไปด้วย ซึ่งเป็นปรากฏการณ์ที่เรียกว่า "Garbage In, Garbage Out"

การติดฉลากข้อมูลในโจทย์ระดับสูงอาจต้องอาศัยผู้เชี่ยวชาญเฉพาะทาง เช่น การระบุตำแหน่งก้อนเนื้อในภาพถ่ายทางการแพทย์ หรือการจำแนกอารมณ์จากข้อความ ซึ่งต้องใช้ต้นทุนและเวลาสูง นี่จึงเป็นข้อจำกัดสำคัญประการหนึ่งของ Supervised Learning เมื่อเทียบกับแนวทางอื่น ๆ เช่น Unsupervised Learning

1.3. การจำแนกประเภทงาน: Regression vs. Classification

การทำความเข้าใจความแตกต่างระหว่างงานประเภท "การถดถอย" (Regression) และ "การจำแนกประเภท" (Classification) เป็นจุดเริ่มต้นที่สำคัญที่สุดในการเลือกใช้อัลกอริทึมที่เหมาะสม สามารถจำแนกความแตกต่างได้ดังนี้



1.3.1. การถดถอย (Regression)

งานประเภท Regression เกี่ยวข้องกับการทำนายผลลัพธ์ที่เป็น "ตัวเลขต่อเนื่อง" (Continuous Value/Quantitative Data) ซึ่งมีคุณสมบัติทางคณิตศาสตร์คือ สามารถวัดค่าได้ เปรียบเทียบมากกว่า-น้อยกว่าได้ และมีความละเอียดเป็นทศนิยมได้ไม่จำกัด

ลักษณะเด่นคือผลลัพธ์มีความต่อเนื่อง (Infinite possibilities within a range)

ตัวอย่างเชิงลึก:

1.3.1.1. การพยากรณ์ทางอุตุนิยมวิทยา: การทำนายอุณหภูมิ (เช่น 29.78°C), ปริมาณน้ำฝน (มิลลิเมตร), หรือความเร็วลม ตัวเลขเหล่านี้มีการเปลี่ยนแปลงอย่างต่อเนื่องและสิ้นไหล

1.3.1.2. การวิเคราะห์ทางการเงิน: การคาดการณ์ราคาหุ้น, ราคาทองคำ, หรืออัตราแลกเปลี่ยน ซึ่งมีความผันผวนเป็นตัวเลขทศนิยม

1.3.1.3. การแพทย์: การทำนายระดับน้ำตาลในเลือด, ความดันโลหิต, หรือระยะเวลาที่คาดว่าจะรอดชีวิตของผู้ป่วย

อัลกอริทึมที่นิยมได้แก่ Linear Regression, Polynomial Regression, Ridge/Lasso Regression, Support Vector Regression (SVR)

1.3.2. การจำแนกประเภท (Classification)

งานประเภท Classification เกี่ยวข้องกับการทำนายผลลัพธ์ที่เป็น "กลุ่ม" หรือ "หมวดหมู่" (Categorical/Discrete Value) หรือข้อมูลเชิงคุณภาพ (Qualitative Data) ซึ่งมีขอบเขตของคำตอบที่ชัดเจนและจำกัด (Finite Set) ไม่สามารถวัดค่าเป็นตัวเลขต่อเนื่องได้

ลักษณะเด่นผลลัพธ์เป็นป้ายกำกับ (Label) หรือคลาส (Class) ที่แยกจากกันโดยเด็ดขาด (Mutually Exclusive)

ประเภทย่อย:

1.3.2.1. Binary Classification: มีคำตอบเพียง 2 ทางเลือก เช่น ใช่/ไม่ใช่, ป่วย/ไม่ป่วย, ผ่าน/ไม่ผ่าน, สเปม/ไม่สเปม

1.3.2.2. Multi-class Classification: มีคำตอบมากกว่า 2 ทางเลือก เช่น การจำแนกสายพันธุ์สัตว์ (แมว/หมา/นก), การตัดเกรด (A/B/C/D/F)

ตัวอย่างเชิงลึก:

1.3.2.3. การประมวลผลภาพ (Computer Vision): การระบุว่าวัตถุในภาพคืออะไร

1.3.2.4. การวิเคราะห์ความเสี่ยง (Risk Scoring): การตัดสินใจอนุมัติหรือไม่อนุมัติสินเชื่อ (โดยผลลัพธ์คือ อนุมัติ/ไม่อนุมัติ)

1.3.2.5. การวินิจฉัยโรค: การระบุว่าเนื้องอกเป็นชนิด "Benign" (ไม่ร้ายแรง) หรือ "Malignant" (ร้ายแรง)

อัลกอริทึมที่นิยม: Logistic Regression (แม้ชื่อเป็น Regression แต่ใช้สำหรับ Classification), Decision Tree, Random Forest, Support Vector Machine (SVM), Naive Bayes


ตารางที่ 1: การเปรียบเทียบเชิงลึกระหว่าง Regression และ Classification

มิติการเปรียบเทียบ	REGRESSION (การถดถอย)	CLASSIFICATION (การจำแนกประเภท)
ประเภทของตัวแปรตาม (TARGET)	ต่อเนื่อง (Continuous) เชิงปริมาณ	ไม่ต่อเนื่อง (Discrete) เชิงคุณภาพ
ลักษณะของผลลัพธ์	ค่าตัวเลขที่วัดระดับได้	ป้ายกำกับ, คลาส, หรือความน่าจะเป็นของคลาส
เป้าหมายของโมเดล	หาเส้นฟังก์ชันที่ฟิตกับจุดข้อมูล (Best Fit Line/Curve)	หาเส้นแบ่งเขตข้อมูล (Decision Boundary)
การวัดผลความผิดพลาด	ระยะห่างระหว่างค่าจริงกับค่าทำนาย (Error Metric)	ความถูกต้องของการจัดกลุ่ม (Accuracy Metric)
ตัวชี้วัดประสิทธิภาพ (METRICS)	MAE, MSE, RMSE, <i>R² score</i>	Accuracy, Precision, Recall, F1-Score, AUC-ROC
ตัวอย่าง	ราคาบ้าน = 3.5 ล้านบาท	ลูกค้าจะซื้อสินค้าหรือไม่ = ใช่ (1)

2. ทฤษฎีคณิตศาสตร์และการทำงานของ Linear Regression

Linear Regression หรือ การถดถอยเชิงเส้น เป็นอัลกอริทึมพื้นฐานที่มีบทบาทสำคัญอย่างยิ่งในการปูพื้นฐานความเข้าใจด้าน Machine Learning แม้จะเป็นโมเดลที่ดูเรียบง่าย แต่หลักการของมันถูกนำไปประยุกต์ใช้ในโมเดลที่ซับซ้อนกว่าอย่าง Neural Networks และ Deep Learning

2.1. โครงสร้างทางคณิตศาสตร์ของ Linear Regression



แนวคิดหลักของ Linear Regression คือการค้นหความสัมพันธ์เชิงเส้น (Linear Relationship) ระหว่างตัวแปรต้น (x) และตัวแปรตาม (y) โดยสมมติว่าการเปลี่ยนแปลงของ y สามารถอธิบายได้ด้วยการเปลี่ยนแปลงของ x ในอัตราส่วนที่คงที่ 13 สมการพื้นฐานที่เราคุ้นเคยจากคณิตศาสตร์ระดับมัธยมปลายคือ:

$$y = mx + C$$

อย่างไรก็ตาม ในบริบทของ Machine Learning เราจะใช้สัญลักษณ์ที่แตกต่างออกไปเพื่อรองรับการขยายขนาดสู่หลายตัวแปร (Multivariate) และสอดคล้องกับพารามิเตอร์ที่โมเดลต้องเรียนรู้:

$$\hat{y} = w_1x_1 + w_2x_2 + \dots + w_nx_n + b$$

หรือเขียนในรูปสัญกรณ์เวกเตอร์ (Vector Notation) ได้ว่า:

$$\hat{y} = w^T x + b$$

องค์ประกอบสำคัญของสมการ:

2.1.1. $\hat{y}$ (y-hat): คือค่าพยากรณ์ที่โมเดลคำนวณได้


2.1.2. x_i (Features): คือค่าของตัวแปรต้นตัวที่ i (เช่น อุณหภูมิสูงสุด, ปริมาณฝน)

2.1.3. w_i (Weights): หรือ ค่าน้ำหนัก เทียบเท่ากับความชัน (m) ในสมการเส้นตรง ค่าน้ำหนักบ่งบอกถึง "อิทธิพล" หรือ "ความสำคัญ" ของตัวแปร x นั้น ๆ ที่มีต่อผลลัพธ์ หาก w มีค่ามาก แสดงว่าการเปลี่ยนแปลงของ x เพียงเล็กน้อยจะส่งผลกระทบต่อ y อย่างมาก หาก w เป็นลบ แสดงว่ามีความสัมพันธ์แบบผกผัน

2.1.4. b (Bias): หรือ ค่าไบแอส เทียบเท่ากับจุดตัดแกน $y(c)$ เป็นค่าพื้นฐานของโมเดล เมื่อตัวแปรต้นทั้งหมดเป็นศูนย์ (Baseline) ค่า Bias ช่วยให้เส้นกราฟสามารถเลื่อนขึ้นลงได้เพื่อให้สอดคล้องกับข้อมูลจริงมากที่สุด โดยไม่ได้ถูกตรึงไว้ที่จุดกำเนิด (0,0)

2.2. การหาเส้นที่ดีที่สุด: Ordinary Least Squares (OLS)

หัวใจสำคัญของการ "เทรน" (Training) โมเดล Linear Regression คือการค้นหาชุดค่า W และ b ที่ดีที่สุด ซึ่งจะทำให้เส้นกราฟที่วาดขึ้นมามีความใกล้เคียงกับจุดข้อมูลจริงทุกจุดมากที่สุด วิธีการทางสถิติมาตรฐานที่ใช้ในการแก้ปัญหานี้เรียกว่า Ordinary Least Squares (OLS)



หลักการของ OLS คือการ **ลดผลรวมของความคลาดเคลื่อนยกกำลังสอง (Minimize Sum of Squared Errors: SSE)** ให้เหลือน้อยที่สุด ความคลาดเคลื่อน หรือ Residual (e) คือระยะห่างในแนวตั้งระหว่างจุดข้อมูลจริง (y) กับเส้นที่โมเดลทำนาย ($\hat{y}$) :

$$e_i = y_i - \hat{y}_i$$

$$CostFunction(J) = \sum_{i=1}^n (y_i - \hat{y}_i)^2$$

ทำไมต้องยกกำลังสอง?

2.2.1. ขจัดปัญหาเครื่องหมาย: ความคลาดเคลื่อนมีทั้งค่าบวก (ทำนายต่ำไป) และค่าลบ (ทำนายสูงไป) หากนำมารวมกันตรง ๆ ค่าอาจจะหักล้างกันจนกลายเป็นศูนย์ ทำให้เข้าใจผิดว่าโมเดลแม่นยำ การยกกำลังสองทำให้ค่าทั้งหมดเป็นบวก

2.2.2. การลงโทษ (Penalization): ฟังก์ชันยกกำลังสองจะให้ค่าความเสียหายสูงมากเมื่อความคลาดเคลื่อนมีขนาดใหญ่ (เช่น $2^2=4$ แต่ $10^2=100$) ซึ่งเป็นการบังคับให้โมเดลพยายามลดความผิดพลาดที่รุนแรงให้ได้มากที่สุด และดึงเส้นกราฟให้ครอบคลุมจุดข้อมูลที่กระจายตัว (Outliers) ได้ดีขึ้น

2.3. ข้อสมมติฐานทางสถิติ (Assumptions of Linear Regression)

ในการนำ Linear Regression ไปใช้งานจริงเพื่อให้ได้ผลลัพธ์ที่เชื่อถือได้ทางสถิติ ข้อมูลควรสอดคล้องกับข้อสมมติฐาน 4 ประการ (Linear Regression Assumptions) ซึ่งเป็นความรู้เชิงลึกที่นักวิเคราะห์ข้อมูลควรทราบ :

2.3.1. Linearity (ความเป็นเส้นตรง): ความสัมพันธ์ระหว่างตัวแปรต้นและตัวแปรตามต้องมีความเป็นเชิงเส้น หากข้อมูลมีความโค้ง (เช่น กราฟพาราโบลา) การใช้ Linear Regression จะทำให้เกิดความผิดพลาดสูง (High Bias / Underfitting)

2.3.2. Independence (ความเป็นอิสระ): ข้อมูลแต่ละตัวอย่าง (Observation) ต้องเป็นอิสระต่อกัน ไม่ควรมีความสัมพันธ์กันเอง (Autocorrelation) ปัญหานี้มักพบในข้อมูลอนุกรมเวลา (Time Series) ซึ่งค่าของวันนี้อาจขึ้นอยู่กับเมื่อวาน

2.3.3. Homoscedasticity (ความแปรปรวนคงที่): ความแปรปรวนของความคลาดเคลื่อน (Residuals) ควรมีค่าคงที่ตลอดช่วงของข้อมูล ไม่ควรมีลักษณะเป็นรูปกรวย (Heteroscedasticity) ที่ช่วงต้นเกาะกลุ่มกันดีแต่ช่วงปลายกระจายตัวกว้าง

2.3.4. Normality of Errors (การแจกแจงปกติของความคลาดเคลื่อน): หากนำค่าความคลาดเคลื่อนทั้งหมดมาพลอตกราฟ ควรได้กราฟระฆังคว่ำ (Normal Distribution) ซึ่งแสดงว่าโมเดลมีความสมดุลงood ไม่มีความเอนเอียงไปทางใดทางหนึ่ง

3. วิศวกรรมข้อมูลและการเตรียมความพร้อม (Data Engineering Pipeline)

ขั้นตอนที่สำคัญและใช้เวลามากที่สุดคือ การเตรียมข้อมูล (Data Preparation) ซึ่งเป็นรากฐานสำคัญตามหลักการ "Garbage In, Garbage Out"

3.1. การทำความสะอาดและจัดการข้อมูล (Data Cleaning)

ไฟล์ข้อมูลในโลกความเป็นจริงมักมีความสกปรก (Dirty Data) และไม่สมบูรณ์ ขั้นตอนการจัดการที่จำเป็นประกอบด้วย:

3.1.1. การจัดการหน่วยความจำ (Memory Management): การโหลดไฟล์ขนาดใหญ่ด้วย Pandas ควรใช้พารามิเตอร์ `low_memory=False` เพื่อป้องกันคำเตือนเกี่ยวกับการเดาประเภทข้อมูล (Dtype Guessing) ซึ่งอาจทำให้เกิดความผิดพลาดในการจัดการหน่วยความจำของคอมพิวเตอร์

3.1.2. การคัดเลือกคุณลักษณะ (Feature Selection): ข้อมูลดิบอาจมีคอลัมน์จำนวนมากที่ไม่เกี่ยวข้อง การเลือกเฉพาะคอลัมน์ที่มีอิทธิพลต่อการทำนาย (เช่น MaxTemp, MinTemp, Precip, MeanTemp) ช่วยลดความซับซ้อนของโมเดล (Model Complexity) และลดความเสี่ยงของการเกิด Overfitting

3.1.3. การจัดการข้อมูลผิดปกติ (Handling Non-numeric/Error Data): ข้อมูลจริงอาจมีข้อความหรืออักขระแปลกปลอมปะปนในช่องตัวเลข การใช้ฟังก์ชัน `pd.to_numeric(..., errors='coerce')` จะช่วยบังคับแปลงข้อมูลให้เป็นตัวเลข และเปลี่ยนค่าที่แปลงไม่ได้ให้กลายเป็น NaN (Not a Number) เพื่อป้องกันไม่ให้โปรแกรมหยุดทำงาน (Crash) ระหว่างการคำนวณทางคณิตศาสตร์

3.1.4. การจัดการค่าสูญหาย (Handling Missing Values): เมื่อข้อมูลเกิดช่องว่าง (NaN) เราต้องตัดสินใจว่าจะจัดการอย่างไร

3.1.4.1. การลบ (Dropping): ใช้คำสั่ง `dropna()` วิธีนี้ง่ายและรวดเร็ว เหมาะสำหรับกรณีที่ข้อมูลมีจำนวนมหาศาลและส่วนที่หายไปมีสัดส่วนน้อย (เช่น ใน EP 9 ข้อมูลหายไปเพียงเล็กน้อยจากแสนกว่าแถว)

3.1.4.2. การแทนที่ (Imputation): ในกรณีที่ข้อมูลมีน้อย การลบทิ้งอาจทำให้เสียข้อมูลสำคัญ อาจใช้วิธีแทนที่ด้วยค่าเฉลี่ย (Mean), มัธยฐาน (Median), หรือใช้โมเดลอื่นมาทำนายค่าที่หายไป

3.2. วิศวกรรมคุณลักษณะสำหรับข้อมูลอนุกรมเวลา (Feature Engineering for Time Series)

โจทย์ "การพยากรณ์อากาศวันพรุ่งนี้" เป็นโจทย์ประเภทอนุกรมเวลา (Time Series) ซึ่งข้อมูลมีการเรียงลำดับตามเวลา การจะใช้ Linear Regression ซึ่งเป็นโมเดลที่มองข้อมูลเป็นจุดอิสระ (Independent) จำเป็นต้องมีเทคนิคการแปลงข้อมูล:

3.2.1. Lag Features (การสร้างฟีเจอร์ย้อนหลัง/ล่วงหน้า): คือการสร้างคอลัมน์เป้าหมาย (NextMeanTemp) โดยการเลื่อน (Shift) ข้อมูล MeanTemp ขึ้นมา 1 บรรทัดด้วยคำสั่ง `.shift(-1)` ผลลัพธ์: ในแถวข้อมูลของ "วันนี้" (Row t) จะประกอบด้วยฟีเจอร์ของวันนี้ (X_t) และมีเฉลยเป็นอุณหภูมิของ "พรุ่งนี้" (Y_{t+1}) อยู่ในบรรทัดเดียวกัน ทำให้โมเดลสามารถเรียนรู้ความสัมพันธ์แบบ $x_t \rightarrow Y_{t+1}$ ได้เหมือนข้อมูลปกติ

3.2.2. การจัดการ Multicollinearity: ข้อควรระวังสำคัญที่ระบุในบทเรียนคือ ไม่ควรนำ MeanTemp ของวันนี้มารวมใน Input Features (X) หากเรามี MaxTemp และ MinTemp อยู่แล้ว เพราะค่าเฉลี่ยคำนวณมาจากค่าสูงสุดและต่ำสุดโดยตรง การใส่ตัวแปรที่มีความสัมพันธ์กันเองสูง (Multicollinearity) เข้าไป จะทำให้โมเดลสับสนในการให้ค่าน้ำหนัก และอาจทำให้ผลการทำนายกว้างได้

3.3. การแบ่งชุดข้อมูล (Train/Test Split Strategy)

กระบวนการแบ่งข้อมูลเป็นขั้นตอนมาตรฐานที่ขาดไม่ได้ โดยทั่วไปจะแบ่งเป็น Training Set และ Test Set (ในสัดส่วน 80:20 หรือ 70:30)

3.3.1. Training Set (80%): ใช้สำหรับให้โมเดลเรียนรู้ ปรับจูนค่าน้ำหนัก (W) และไบแอส (b) เพื่อลดค่า Error

3.3.2. Test Set (20%): ทำหน้าที่เป็น "ข้อสอบลับ" (Unseen Data) ที่โมเดลไม่เคยเห็นมาก่อน ใช้เพื่อวัดความสามารถในการ "วางนัยทั่วไป" (Generalization) ว่าโมเดลสามารถนำความรู้ไปใช้กับสถานการณ์จริงได้ดีแค่ไหน

3.3.3. Random State: การกำหนดค่า `random_state` (เช่น 0 หรือ 42) ในการแบ่งข้อมูลมีความสำคัญต่อความสามารถในการทำซ้ำ (Reproducibility) เพื่อให้แน่ใจว่าผลการทดลองจะคงที่ทุกครั้งที่เรารันโปรแกรม ไม่เปลี่ยนแปลงไปตามการสุ่มแต่ละรอบ

4. การวัดผลและประเมินประสิทธิภาพ (Evaluation Metrics)

ในงาน Regression เราไม่สามารถวัดผลด้วยความแม่นยำ (Accuracy) เป็นเปอร์เซ็นต์ความถูกต้องได้ เหมือนงาน Classification (เช่น ทายถูก 90 จาก 100 รูป) เนื่องจากผลลัพธ์เป็นตัวเลขต่อเนื่อง เราจึงต้องวัด "ระยะห่าง" หรือ "ระดับความคลาดเคลื่อน" แทน โดยใช้ตัวชี้วัดหลัก 3 ตัว ดังนี้ :

4.1. Mean Absolute Error (MAE)

4.1.1. สูตรทางคณิตศาสตร์:

$$MAE = \frac{1}{n} \sum_{i=1}^n |y_i - \hat{y}_i|$$

4.1.2. คำอธิบาย: คือ "ค่าเฉลี่ยของความคลาดเคลื่อนสัมบูรณ์" เป็นการนำผลต่างระหว่างค่าจริงและค่าพยากรณ์มาหาค่าสัมบูรณ์ (Absolute) แล้วเฉลี่ยกัน

4.1.3. การตีความ: ค่า MAE จะมีหน่วยเดียวกับข้อมูล (เช่น องศาเซลเซียส) บอกเราตรง ๆ ว่า "โดยเฉลี่ยแล้ว โมเดลทายผิดไปกี่หน่วย" คำนี้น่าเข้าใจง่ายและมีความเป็นธรรมชาติ (Robust) ต่อข้อมูลที่ผิดปกติ (Outliers) ในระดับหนึ่ง

4.1.4. ตัวอย่างในบทเรียน: $MAE = 1.11^{\circ}\text{C}$ หมายความว่า โดยเฉลี่ยโมเดลทายอุณหภูมิคลาดเคลื่อนไปบวกลบประมาณ 1 องศา

4.2. Root Mean Squared Error (RMSE)

4.2.1. สูตรทางคณิตศาสตร์:

$$RMSE = \sqrt{\frac{1}{n} \sum_{j=1}^n (y_i - \hat{y}_i)^2}$$

4.2.2. คำอธิบาย: คือ "รากที่สองของค่าเฉลี่ยความคลาดเคลื่อนยกกำลังสอง"

4.2.3. การตีความ: มีหน่วยเดียวกับข้อมูลเช่นกัน แต่ค่ามักจะสูงกว่าหรือเท่ากับ MAE เสมอ

4.2.4. จุดเด่นเชิงวิเคราะห์: RMSE มีความไวต่อความผิดพลาดขนาดใหญ่ (Large Errors) มากกว่า MAE เพราะขั้นตอนการยกกำลังสองจะขยายขนาดของความผิดพลาดที่สูงให้ยิ่งสูงขึ้นไปอีก (เช่น Error=10 เมื่อยกกำลังสองจะเป็น 100 ในขณะที่ Error=1 ยังคงเป็น 1) ดังนั้น หากค่า RMSE สูงกว่า MAE มาก ๆ แสดงว่าโมเดลมีความไม่เสถียร (Variance High) คือทายถูกเป็นส่วนใหญ่แต่มีบางครั้งที่ทายผิดพลาดอย่างรุนแรง

4.3. R-Squared (R^2 Score)

4.3.1. สูตรทางคณิตศาสตร์:

$$R^2 = 1 - \frac{\sum (y_i - \hat{y}_i)^2}{\sum (y_i - \bar{y})^2}$$

4.3.2. คำอธิบาย: หรือ "สัมประสิทธิ์การตัดสินใจ" (Coefficient of Determination) เป็นการเปรียบเทียบความผิดพลาดของโมเดลเรา ($\hat{y}$) กับความผิดพลาดของโมเดลพื้นฐานที่ทายด้วยค่าเฉลี่ย ($\bar{y}$)

4.3.3. การตีความ: เป็นค่าสัดส่วนที่ไม่มีหน่วย มีค่าสูงสุดคือ 1.0 (หรือ 100%)

4.3.3.1. $R^2 \approx 1$: โมเดลมีความสามารถสูงมาก ตัวแปรต้น (x) สามารถอธิบายความผันแปรของตัวแปรตาม (y) ได้เกือบทั้งหมด

4.3.3.2. $R^2 \approx 0$: โมเดลไม่ดีกว่าการเดาด้วยค่าเฉลี่ย (Mean)

4.3.3.3. $R^2 < 0$: โมเดลแย่กว่าการเดาด้วยค่าเฉลี่ย (อาจเกิดจากข้อมูลไม่มีความสัมพันธ์กันเลย หรือเลือกโมเดลผิดประเภท)


4.3.4. ตัวอย่างในบทเรียน: $R^2 = 0.942$ (94.2%) แสดงว่าตัวแปรสภาพอากาศวันนี้ (สูงสุด/ต่ำสุด/ฝน) มีอิทธิพลอย่างมากและสามารถใช้อธิบายอุณหภูมิของวันพรุ่งนี้ได้อย่างแม่นยำ

ตารางที่ 2: การเลือกใช้ Metrics ในสถานการณ์ต่าง ๆ

สถานการณ์	ควรใช้ METRIC ไດ?	เหตุผล
ต้องการอธิบายให้คนทั่วไปเข้าใจง่าย	MAE	แปลความหมายได้ตรงตัว (เช่น ผิดไปกี่บาท, กี่องศา)
ต้องการโมเดลที่ห้ามผิดพลาดรุนแรง (เช่น การแพทย์, ความปลอดภัย)	RMSE	ลงโทษ (Penalize) ความผิดพลาดสูง ๆ อย่างหนัก เพื่อบีบให้โมเดลระวัง Outliers
ต้องการเปรียบเทียบว่าโมเดล "เก่ง" แค่ไหนในเชิงสถิติ	R^2	บอกสัดส่วนความสัมพันธ์ได้ดี ไม่ขึ้นกับหน่วยของข้อมูล

5. แนวคิดขั้นสูงและการแก้ปัญหา (Advanced Concepts & Troubleshooting)

เพื่อให้ผู้เรียนมีความเข้าใจที่ลึกซึ้งและสามารถนำความรู้ไปประยุกต์ใช้ได้อย่างยืดหยุ่น จำเป็นต้องเข้าใจปัญหาคลาสสิก 2 ประการที่นักพัฒนา AI ทุกคนต้องเจอ คือ Overfitting และ Underfitting ซึ่งเกี่ยวข้องกับทฤษฎี Bias-Variance Tradeoff



5.1. Overfitting (การเรียนรู้เกินพอดี / High Variance)

5.1.1. อาการ: เปรียบเสมือนนักเรียนที่ "ท่องจำข้อสอบ" อย่างแม่นยำ ทำคะแนนสอบเก็บคะแนนในห้องเรียน (Training Set) ได้เต็มหรือเกือบเต็ม แต่พอไปสอบจริงหรือเจอโจทย์ประยุกต์ (Test Set) กลับทำไม่ได้เลย ความแม่นยำตกวบ

5.1.2. สาเหตุ: โมเดลมีความซับซ้อนมากเกินไป (Too Complex) จนพยายามเรียนรู้ทุกจุดข้อมูล รวมถึง "สัญญาณรบกวน" (Noise) หรือรายละเอียดปลีกย่อยที่ไม่ใช่สาระสำคัญ ทำให้โมเดลสร้างกฎที่จำเพาะเจาะจงเกินไปจนไม่สามารถนำไปใช้กับข้อมูลอื่นได้

5.1.3. แนวทางแก้ไข:

5.1.3.1. เพิ่มข้อมูล (More Data): ให้โมเดลเห็นตัวอย่างที่หลากหลายขึ้น

5.1.3.2. ลดความซับซ้อน (Simplify Model): ตัดฟีเจอร์ที่ไม่จำเป็นออก (Feature Selection) หรือลดระดับของสมการ (เช่น จาก Polynomial เป็น Linear)

5.1.3.3. Regularization: เทคนิคทางคณิตศาสตร์ (L1/L2) เพื่อลงโทษค่าน้ำหนัก (sw) ที่สูงเกินไป (จะมีการกล่าวถึงในบทเรียนขั้นสูง)

5.2. Underfitting (การเรียนรู้ไม่เพียงพอ / High Bias)

5.2.1. อาการ: เปรียบเสมือนนักเรียนที่ "เรียนไม่รู้เรื่อง" หรือ "ทำการบ้านไม่ได้" โมเดลทำผลงานได้แย่ทั้งใน Training Set และ Test Set (ค่า Error สูงทั้งคู่)

5.2.2. สาเหตุ: โมเดลมีความซับซ้อนน้อยเกินไป (Too Simple) ไม่สามารถจับรูปแบบความสัมพันธ์ที่ซับซ้อนของข้อมูลได้ เช่น ข้อมูลมีความโค้งเป็นรูปตัว U แต่เราพยายามใช้เส้นตรง (Linear) ไปลากผ่าน ทำให้ไม่ว่าจะลากอย่างไรก็ไม่สามารถเข้าใกล้จุดข้อมูลส่วนใหญ่ได้

5.2.3. แนวทางแก้ไข:

5.2.3.1. เพิ่มความซับซ้อน (Increase Complexity): เปลี่ยนไปใช้โมเดลที่มีความยืดหยุ่นสูงขึ้น (เช่น Decision Tree, Neural Network)

5.2.3.2. ฟีเจอร์ (Feature Engineering): หาข้อมูลนำเข้าใหม่ ๆ ที่มีความสัมพันธ์กับผลลัพธ์มากขึ้น

5.2.3.3. ลดการทำ Regularization: ปลดปล่อยให้โมเดลมีอิสระในการเรียนรู้มากขึ้น

ภาพจำ (Mental Model): เป้าหมายของการสร้าง AI คือการหาจุดสมดุล (Sweet Spot) ระหว่าง Bias และ Variance ซึ่งเป็นจุดที่กราฟ Error ของ Test Set มีค่าต่ำที่สุด ก่อนที่มันจะเริ่มดีดตัวสูงขึ้นสวนทางกับ Training Error

6. การประยุกต์ใช้จริงและบทสรุป (Practical Application & Conclusion)

6.1. การนำโมเดลไปใช้งาน (Deployment)

6.1.1. Persistence: การใช้ `joblib.dump` ช่วยให้เราสามารถ "บันทึกสถานะสมอง" ของ AI (ค่า w และ b ที่ดีที่สุด) เก็บไว้เป็นไฟล์ (.pkl) เปรียบเสมือนการเซฟเกม ทำให้ไม่ต้องเสียเวลาเทรนใหม่ทุกครั้งที่จะใช้งาน

6.1.2. Inference: การใช้ `joblib.load` เพื่อเรียกคืนโมเดลและนำมาทำนายข้อมูลชุดใหม่ (New Data) เช่น การจำลองสถานการณ์ "วันแดดร้อน" หรือ "วันฝนตก" ผลลัพธ์ที่ได้จากการทดลองในวิดีโอแสดงให้เห็นว่าโมเดลสามารถให้คำตอบที่สมเหตุสมผลตามตรรกะของมนุษย์ (วันร้อน $\rightarrow$ อุณหภูมิพุ่งนี้สูง, วันหนาว $\rightarrow$ อุณหภูมิพุ่งนี้ต่ำ) ซึ่งยืนยันว่าคณิตศาสตร์ Linear Regression สามารถจับรูปแบบความสัมพันธ์ของธรรมชาติได้จริง

6.2. บทสรุปและก้าวต่อไป

หน่วยการเรียนรู้นี้ได้ทำหน้าที่เชื่อมโยงสะพานระหว่าง "ทฤษฎี" และ "การปฏิบัติ" อย่างสมบูรณ์ ผู้เรียนได้ได้รับความรู้ตั้งแต่รากฐานของ Supervised Learning ความแตกต่างของงาน AI ประเภทต่าง ๆ กลไกคณิตศาสตร์เบื้องหลัง Linear Regression ไปจนถึงกระบวนการทางวิศวกรรมข้อมูลที่ใช้สำหรับการสร้างโมเดลที่มีคุณภาพ

องค์ความรู้เรื่องการแบ่งข้อมูล (Train/Test Split), การวัดผลด้วย RMSE/MAE, และความเข้าใจเรื่อง Overfitting/Underfitting ในบทนี้ จะเป็น "เครื่องมือทางความคิด" (Cognitive Tools) ที่สำคัญอย่างยิ่งเมื่อผู้เรียนก้าวเข้าสู่เนื้อหาที่ซับซ้อนขึ้นในบทถัดไป เช่น Neural Networks และ Deep Learning ซึ่งแม้จะมีโครงสร้างที่ซับซ้อนกว่า แต่ก็ยังคงวางอยู่บนรากฐานของแนวคิดเหล่านี้ทั้งสิ้น

อ้างอิง

365 Data Science. (2021, November 10). *OLS assumptions*.

<https://365datascience.com/tutorials/statistics-tutorials/ols-assumptions/>

Abdulazeez, F. (2023, June 17). Essential regression evaluation metrics: MSE, RMSE, MAE, R^2 , and adjusted R^2 . *Medium*. <https://farshadabdulazeez.medium.com/essential-regression-evaluation-metrics-mse-rmse-mae-r%C2%B2-and-adjusted-r%C2%B2-0600daa1c03a>

Amazon Web Services. (n.d.). *Model fit: Underfitting vs. overfitting*.

<https://docs.aws.amazon.com/machine-learning/latest/dg/model-fit-underfitting-vs-overfitting.html>

Analytics Vidhya. (2020, June 29). Elucidating bias-variance, under-fitting and over-fitting.

Medium. <https://medium.com/analytics-vidhya/elucidating-bias-variance-under-fitting-and-over-fitting-273846621622>

Analytics Vidhya. (2021, July 5). MAE, MSE, RMSE, coefficient of determination, adjusted R-squared — Which metric is better? *Medium*. <https://medium.com/analytics-vidhya/mae-mse-rmse-coefficient-of-determination-adjusted-r-squared-which-metric-is-better-cd0326a5697e>

Cetin, R. K. (2020, August 24). The importance of splitting datasets into training, validation and test sets. *Medium*. <https://ruveydakardelcetin.medium.com/the-importance-of-splitting-datasets-into-training-validation-and-test-sets-417caaeae91d>

Clarity. (n.d.). R^2 & RMSE. <https://click.clarity.io/knowledge/r2-rmse>

Clemson University. (n.d.). *Regression*. Department of Physics and Astronomy.

<https://science.clemson.edu/physics/labs/tutorials/regression/index.html>

Codecademy. (n.d.). *Regression vs. classification*.

<https://www.codecademy.com/article/regression-vs-classification>

CodeSignal. (n.d.). *Understanding MSE, MAE, RMSE, and their differences*.

<https://codesignal.com/learn/courses/deep-dive-into-regression-and-classification-metrics/lessons/understanding-mse-mae-rmse-and-their-differences>

DataCamp. (n.d.). *OLS regression in R and Python*. <https://www.datacamp.com/tutorial/ols-regression>

DeepLearning.AI Community. (2023, July). *Can someone explain what weights and biases are?* [Online forum post]. <https://community.deeplearning.ai/t/can-someone-explain-what-weights-and-biases-are/394280>

Exxact Corp. (2020, March 18). *Overfitting, generalization, the bias-variance tradeoff*. <https://www.exxactcorp.com/blog/deep-learning/overfitting-generalization-the-bias-variance-tradeoff>

Flitto DataLab. (2023, April 18). *What is underfitting and overfitting? Easy example*. <https://datalab.flitto.com/en/company/blog/what-is-underfitting-and-overfitting-easy-example/>

Frost, J. (n.d.). *OLS linear regression assumptions*. Statistics By Jim. <https://statisticsbyjim.com/regression/ols-linear-regression-assumptions/>

GeeksforGeeks. (n.d.). *ML | Classification vs. regression*. <https://www.geeksforgeeks.org/machine-learning/ml-classification-vs-regression/>

GeeksforGeeks. (n.d.). *Supervised machine learning*. <https://www.geeksforgeeks.org/machine-learning/supervised-machine-learning/>

Google Cloud. (n.d.). *What is supervised learning?* <https://cloud.google.com/discover/what-is-supervised-learning>

Google Developers. (n.d.). *Linear regression*. Machine Learning Crash Course. <https://developers.google.com/machine-learning/crash-course/linear-regression?hl=th>

Gultekin, H. (2020, November 23). *Classification vs regression*. Medium. <https://medium.com/@hazallgultekin/classification-vs-regression-e15c619604f7>

Hex. (n.d.). *Detecting and remedying multicollinearity*. <https://hex.tech/blog/detecting-and-remedying-multicollinearity/>

IBM. (n.d.). *Classification vs. regression*. <https://www.ibm.com/think/topics/classification-vs-regression>

IBM. (n.d.). *Multicollinearity*. <https://www.ibm.com/think/topics/multicollinearity>

IBM. (n.d.). *Overfitting vs. underfitting*. <https://www.ibm.com/think/topics/overfitting-vs-underfitting>

IBM. (n.d.). *What is supervised learning?* <https://www.ibm.com/think/topics/supervised-learning>

Manoj, M. (2020, June 1). Assumptions of linear regression clearly explained. *Medium*. <https://medium.com/@mangammanoj/assumptions-of-linear-regression-clearly-explained-1935984c7208>

ML Cheatsheet. (n.d.). *Linear regression*. ReadTheDocs. https://ml-cheatsheet.readthedocs.io/en/latest/linear_regression.html

Ordinary least squares. (2024, May 15). In *Wikipedia*. https://en.wikipedia.org/wiki/Ordinary_least_squares

Patel, D. (2020, March 18). Linear regression. *Medium*. <https://deeppatel23.medium.com/linear-regression-9a8d3b141b6b>

Sabbha, M. (2023, August 3). Understanding MAE, MSE, and RMSE: Key metrics in machine learning. *Dev.to*. https://dev.to/mondal_sabbha/understanding-mae-mse-and-rmse-key-metrics-in-machine-learning-4la2

Sharma, D. (2019, August 5). Step by step machine learning: Linear regression. *Medium*. <https://medium.com/@deek.sharma/step-by-step-machine-learning-linear-regression-712eb215d52f>

Srivastava, S. (2023, July 15). Evaluating model performance: Understanding MAE, MSE, RMSE, and R^2 score. *Medium*. <https://medium.com/@srivastavashivansh8922/evaluating-model-performance-understanding-mae-mse-rmse-and-r%C2%B2-score-5516e10fe8d6>

Supervised learning. (2024, June 2). In *Wikipedia*. https://en.wikipedia.org/wiki/Supervised_learning

Towards Data Science. (2019, September 24). What are RMSE and MAE? *Medium*. <https://towardsdatascience.com/what-are-rmse-and-mae-e405ce230383/>

Udacity. (2025, February). *Regression vs. classification: Key differences and when to use each*. <https://www.udacity.com/blog/2025/02/regression-vs-classification-key-differences-and-when-to-use-each.html>

Venkatesh, S. (2023, October 16). Underfitting vs overfitting with visualization. *Medium*.
<https://medium.com/@shrinath.venkatesh/underfitting-vs-overfitting-with-visualization-891b5c686a8b>

XLSTAT. (n.d.). *Ordinary least squares regression (OLS)*.
<https://www.xlstat.com/solutions/features/ordinary-least-squares-regression-ols>