

ใบงานที่ 3 การจัดการและเตรียมข้อมูลสำหรับสร้างโมเดล AI

วัตถุประสงค์การเรียนรู้

1. เขียนคำสั่ง Python เพื่อทำความสะอาดข้อมูล (Data Cleaning) ได้ถูกต้องตามเงื่อนไข
2. เขียนคำสั่ง Python เพื่อปรับสเกลข้อมูล (Feature Scaling) ให้อยู่ในมาตรฐานเดียวกัน
3. เขียนคำสั่ง Python เพื่อแปลงข้อมูลเชิงหมวดหมู่ (Categorical Data) ให้เป็นตัวเลข (Encoding) ได้
4. เขียนคำสั่ง Python เพื่อแบ่งชุดข้อมูล (Data Splitting) สำหรับสอนและทดสอบโมเดลได้
5. บอกจำนวนค่าต่ำสุด สูงสุด หรือค่าเฉลี่ยของข้อมูลหลังการปรับสเกลได้
6. บอกค่าสถิติที่ได้หลังจากการทำความสะอาดข้อมูล
7. บอกค่าตัวเลขที่ได้จากการแปลงข้อมูลเชิงหมวดหมู่
8. บอกจำนวนแถวของชุดข้อมูลสอน (Train Set) และชุดข้อมูลทดสอบ (Test Set) ตามสัดส่วนที่กำหนดได้

เครื่องมือและอุปกรณ์

1. เครื่องคอมพิวเตอร์ที่ติดตั้งโปรแกรม PyCharm IDE
2. ไฟล์ข้อมูลดิบ lab1.csv
3. เอกสารใบความรู้หน่วยที่ 3
4. แบบฟอร์มบันทึกผลการปฏิบัติงาน (ท้ายใบงาน)

ลำดับขั้นตอนการปฏิบัติงาน

คำชี้แจง: ให้ผู้เรียนเขียนโค้ดลงในไฟล์ main.py ตามขั้นตอนต่อไปนี้

```
# ขั้นตอนที่ 1: การทำความสะอาดข้อมูล (Data Cleaning)
# 1. นำไฟล์ lab1.csv จากโฟลเดอร์ Data management มาเป็น Dataset สำหรับ AI ทำนายราคาารถ
# 2. เขียนคำสั่ง นำเข้าไลบรารี Pandas และโหลดไฟล์ CSV เข้าสู่ DataFrame
import pandas as pd
df = pd.read_csv('lab1.csv')
# 3. เขียนคำสั่ง แปลงรูปแบบข้อมูล (Data Formatting)
# - แปลงคอลัมน์ราคา (Price) จากตัวอักษรให้เป็นตัวเลข
df['Price'] = df['Price'].astype(str).str.replace(',', '')
df['Price'] = pd.to_numeric(df['Price'], errors='coerce')
# - กำจัดช่องว่างและจัดรูปแบบตัวอักษรในคอลัมน์ชื่อยี่ห้อ (Brand)
df['Brand'] = df['Brand'].str.strip().str.title()
# 4. เขียนคำสั่ง จัดการข้อมูลสูญหาย (Missing Values)
# - ลบแถวข้อมูล หากค่าว่างเกิดในคอลัมน์เป้าหมาย (Target/Label)
df = df.dropna(subset=['Price'])
# - ใช้เทคนิคการแทนค่าข้อมูลที่เหมาะสมหากค่าว่างเกิดในคอลัมน์คุณลักษณะ (Feature)
import numpy as np
df['Brand'] = df.groupby('Model')['Brand'].transform(
    lambda x: x.fillna(
        x.mode()[0] if not x.mode().empty else np.nan
    )
)
# หากหาข้อมูลที่ถูกต้องมาแทนที่ไม่ได้ให้ลบทิ้ง
df = df.dropna(subset=['Brand'])
# 5. เขียนคำสั่ง จัดการข้อมูลผิดปกติ (Handling Outliers)
# - กรองข้อมูลรถที่มีปีผลิต (Year) ผิดปกติ
df = df[(df['Year'] >= 1900) & (df['Year'] <= 2026)]
# - กรองข้อมูลรถที่มีเลขไมล์ (Mileage) ผิดปกติ
df = df[df['Mileage'] >= 0]
# 6. เขียนคำสั่ง ลบข้อมูลที่ซ้ำซ้อน (Drop Duplicates)
df = df.drop_duplicates()
```

```

# ขั้นตอนที่ 2: การปรับสเกลข้อมูล (Feature Scaling)
# 1. นำเข้าไลบรารีที่จำเป็นสำหรับการสเกลข้อมูล
from sklearn.preprocessing import MinMaxScaler, StandardScaler

# 2. เขียนคำสั่ง เพื่อทำการปรับสเกลแบบ Normalization กับ Price
# - สร้างตัวแปรใหม่ Price_Norm เก็บคอลัมน์ Price ที่สเกลแล้ว
min_max_scaler = MinMaxScaler()
Price_Norm = min_max_scaler.fit_transform(df[['Price']])
df['Price'] = Price_Norm

# - เขียนคำสั่งตรวจสอบผลลัพธ์ว่าค่าต่ำสุดเป็น 0.0 และสูงสุดเป็น 1.0 หรือไม่
print(f"Price -> Min: {df['Price'].min()}, Max: {df['Price'].max()}")

# 3. เขียนคำสั่ง เพื่อทำการปรับสเกลแบบ Standardization กับ Mileage
# - สร้างตัวแปรใหม่ Mileage_Std เก็บคอลัมน์ Mileage ที่สเกลแล้ว
std_scaler = StandardScaler()
Mileage_Std = std_scaler.fit_transform(df[['Mileage']])
df['Mileage'] = Mileage_Std

# เขียนคำสั่งตรวจสอบผลลัพธ์ (ค่าเฉลี่ยของคอลัมน์นี้ควรเข้าใกล้ 0.0)
print(f"Mileage -> Mean: {df['Mileage'].mean():.4f}")

# ขั้นตอนที่ 3: วิศวกรรมคุณลักษณะ (Feature Engineering)
# 1. เขียนคำสั่ง การคัดเลือกคุณลักษณะ (Feature Selection)
# - ให้ทำการลบคอลัมน์ที่ไม่เกี่ยวข้องกับการทำนายทิ้ง ได้แก่ Car_ID, Owner_Name และ
Lucky_Number
cols_to_drop = ['Car_ID', 'Owner_Name', 'Lucky_Number']
df = df.drop(columns=cols_to_drop)

# 2. เขียนคำสั่ง การแปลงข้อมูลหมวดหมู่ (Encoding Categorical Data)
# - ให้ใช้เทคนิค Label Encoding หรือ .map() กับคอลัมน์ Fuel_Type (ชนิดเชื้อเพลิง) เพื่อแปลงค่า
Petrol, Diesel, Hybrid ให้เป็นตัวเลข
from sklearn.preprocessing import LabelEncoder
le_encoder = LabelEncoder()
df['Fuel_Type'] = le_encoder.fit_transform(df['Fuel_Type'])

# - ให้ใช้เทคนิค Label Encoding กับคอลัมน์ Brand (ยี่ห้อรถ) เพื่อแปลงยี่ห้อรถให้เป็นตัวเลข
df['Brand'] = le_encoder.fit_transform(df['Brand'])

# - ให้ใช้เทคนิค Label Encoding กับคอลัมน์ Model (โมเดลรถ) เพื่อแปลงยี่ห้อรถให้เป็นตัวเลข

```

```

df['Model'] = le_encoder.fit_transform(df['Model'])
# (ในใบงานนี้เราจะใช้ Label Encoding เพื่อความง่ายในการเขียนโค้ดและการดูผลลัพธ์เบื้องต้น แม้ว่าทาง
ทฤษฎี Brand และ Model จะเป็นข้อมูล Nominal ที่ควรใช้ One-Hot Encoding ก็ตาม)

# ขั้นตอนที่ 4: การแบ่งชุดข้อมูล (Train-Test Split)
# 1. เขียนคำสั่ง แยกข้อมูลออกเป็น 2 ส่วน:
# - ตัวแปร X (Features): เก็บข้อมูลคุณลักษณะทั้งหมด
feature_cols = ['Year', 'Mileage', 'Brand', 'Fuel_Type']
X = df[feature_cols]
# - ตัวแปร y (Target): เก็บข้อมูลค่าตอบที่ต้องการทำนาย
y = df['Price']
# 2. เขียนคำสั่ง นำเข้าฟังก์ชัน train_test_split จากไลบรารี sklearn
from sklearn.model_selection import train_test_split
# 3. เขียนคำสั่ง แบ่งข้อมูล X และ y ออกเป็นชุดสอน (Train Set) และชุดทดสอบ (Test Set) โดยกำหนด
ขนาด Test Set = 20%
X_train, X_test, y_train, y_test = train_test_split(
    X, y, test_size=0.2, random_state=42
)
# 4. เขียนคำสั่ง ตรวจสอบจำนวนของข้อมูลทั้ง 4 ตัวแปรที่ได้ (X_train, X_test, y_train, y_test)
print(f"X_train len: {len(X_train)}")
print(f"X_test len: {len(X_test)}")
print(f"y_train len: {len(y_train)}")
print(f"y_test len: {len(y_test)}")

```

แบบบันทึกผลการปฏิบัติงาน

ส่วนที่ 1: ผลการทำความสะอาดข้อมูล (Data Cleaning Results)

คำชี้แจง: ให้ดูผลลัพธ์จากหน้าจอ Terminal หลังรันคำสั่ง แล้วบันทึกค่าที่ได้ลงในช่องว่าง

- จำนวนข้อมูล (Rows):
 - จำนวนแถวก่อนทำความสะอาด (Original Data): แถว
 - จำนวนแถวหลังทำความสะอาด (Cleaned Data): แถว
- การจัดการข้อมูลผิดปกติ (Outliers):
 - ปีผลิต (Year): ค่าต่ำสุด (Min) ที่เหลืออยู่คือปี ค.ศ. (ต้องไม่ต่ำกว่า 1900)
 - เลขไมล์ (Mileage): ค่าต่ำสุด (Min) ที่เหลืออยู่คือ (ต้องไม่ติดลบ)
- การแปลงข้อมูล (Formatting):
 - ชนิดข้อมูล (Dtype) ของคอลัมน์ Price ปัจจุบันคือ:

ส่วนที่ 2: ผลการปรับสเกลข้อมูล (Feature Scaling Results)

- Normalization (Min-Max Scaling) บนคอลัมน์ Price:
 - ค่าต่ำสุด (Min) ของ Price:
 - ค่าสูงสุด (Max) ของ Price:
- Standardization (Z-Score Scaling) บนคอลัมน์ Mileage:
 - ค่าเฉลี่ย (Mean) ของ Mileage:

ส่วนที่ 3: ผลการทำวิศวกรรมคุณลักษณะ (Feature Engineering)

- รายชื่อคอลัมน์ที่ไม่เกี่ยวข้องและถูกตัดออก (Drop) คือ?

.....

- รายชื่อคอลัมน์ที่ เหลืออยู่ สำหรับนำไปใช้ทำนายผล คือ?

.....

3. จงบันทึกค่าตัวเลขที่ได้จากการแปลง (Mapping/Label Encoding) ของข้อมูลตัวอย่าง 3 แถวแรก

รายการ ที่	ค่าเดิมของ Brand (เช่น Toyota)	ค่าตัวเลขใหม่ของ Brand (เช่น 0)	ค่าเดิมของ Fuel_Type (เช่น Petrol)	ค่าตัวเลขใหม่ของ Fuel_Type (เช่น 1)
1				
2				
3				

ส่วนที่ 4: ผลการแบ่งชุดข้อมูล (Data Splitting Results)

คำชี้แจง: บันทึกขนาด (Shape) ของตัวแปรที่ได้จากการแบ่ง Train/Test

- สัดส่วนการแบ่งข้อมูล: : (Train : Test)
- จำนวนข้อมูลในชุดสอน (Train Set):
 - X_train มีจำนวน แถว
 - y_train มีจำนวน แถว
- จำนวนข้อมูลในชุดทดสอบ (Test Set):
 - X_test มีจำนวน แถว
 - y_test มีจำนวน แถว