

ใบงานที่ 9 การปรับแต่งโมเดลภาษา (LLM Fine-Tuning)

วัตถุประสงค์การเรียนรู้

1. เขียนคำสั่งภาษา Python เพื่อเตรียมข้อมูลและตั้งค่าการปรับแต่งโมเดล (Fine-Tune) สำหรับสร้างแชทบอทเฉพาะทาง จากชุดข้อมูลที่กำหนดให้ ได้อย่างถูกต้องตามขั้นตอน
2. เขียนคำสั่งภาษา Python เพื่อทดสอบและประเมินผลความแม่นยำของโมเดลที่ผ่านการปรับแต่ง จากชุดคำถามทดสอบที่สร้างขึ้น ได้อย่างถูกต้อง
3. เขียนคำสั่งภาษา Python เพื่อผสานค่าน้ำหนัก (Model Merging) และบันทึกโมเดล (Export) สำหรับเตรียมนำไปใช้งานจริง ได้อย่างสมบูรณ์

เครื่องมือและอุปกรณ์

1. เครื่องคอมพิวเตอร์ที่มีการ์ดจอ (GPU) และติดตั้งโปรแกรม PyCharm IDE
2. สิทธิ์การเข้าถึงโมเดลจาก Hugging Face (เช่น google/gemma-3-1b-it)
3. ไฟล์ชุดข้อมูล dataset.json (ชุดข้อมูลถาม-ตอบเรื่องมะเขือเทศ)
1. คอมพิวเตอร์ที่มี NVIDIA GPU ที่รองรับ CUDA
4. เอกสารใบความรู้หน่วยที่ 9
5. แบบฟอร์มบันทึกผลการปฏิบัติงาน (ท้ายใบงาน)

ลำดับขั้นตอนการปฏิบัติงาน

คำชี้แจง: ให้ผู้เรียนเขียนโค้ดลงในโปรแกรม PyCharm ตามขั้นตอนต่อไปนี้ รันโปรแกรม และนำผลลัพธ์ที่ปรากฏบนหน้าจอ Terminal มาบันทึกลงในแบบฟอร์มท้ายใบงาน

ขั้นตอนที่ 1: การปรับแต่งโมเดล (Fine-Tuning เพื่อสร้างแชทบอท)

1. นำไฟล์ dataset.json มาวางในโฟลเดอร์โปรเจกต์
2. สร้างไฟล์ Fine-tune.py เขียนโค้ดเพื่อโหลด Base Model แบบบีบอัด 4-bit (Quantization) เพื่อประหยัดทรัพยากรเครื่อง
3. เขียนคำสั่งตั้งค่า LoraConfig เพื่อสร้างแวนตาความรู้ (Adapter) โดยระบุ target_modules ที่เกี่ยวข้องกับระบบความสนใจ (Attention) ของ AI
4. สั่งรันการฝึกสอน (Train) ด้วย Trainer และรอจนกระทั่งโปรแกรมบันทึกโฟลเดอร์ gemma3-finetuned สำเร็จ

ขั้นตอนที่ 2: การประเมินผลโมเดล (Model Evaluation)

1. สร้างไฟล์ evaluate_model.py เพื่อโหลด Base Model มาสมทบกับ Adapter ที่เพิ่งฝึกสอนเสร็จ
2. สร้างชุดคำถามทดสอบ (Test Set) ที่มีทั้งคำถามในเนื้อหา (เช่น ลักษณะของมะเขือเทศ) และคำถามหลอกนอกเนื้อหา (เช่น การปลูกแตงโม)
3. รันโปรแกรมเพื่อทดสอบถาม-ตอบ และสังเกตพฤติกรรมการตอบคำถามของแชทบอท

ขั้นตอนที่ 3: การบันทึกโมเดลเพื่อนำไปใช้งานจริง (Model Export)

1. สร้างไฟล์ export_model.py เขียนคำสั่งโหลด Base Model แบบความละเอียดเต็ม 16-bit โดยบังคับให้โหลดเข้า CPU (device_map="cpu") เพื่อป้องกัน VRAM เต็ม
2. โหลด Adapter มาสมทบ และใช้คำสั่ง merge_and_unload() เพื่อหลอมรวมค่าน้ำหนักความรู้ใหม่เข้ากับสมองหลักแบบถาวร
3. บันทึกโมเดล (Save) ไปยังโฟลเดอร์ใหม่ เช่น gemma3-bot-final

แบบบันทึกผลการปฏิบัติงาน

ส่วนที่ 1: การตั้งค่าพารามิเตอร์สำหรับการปรับแต่งโมเดล (Fine-Tuning)

1. ในขั้นตอนการแปลงข้อมูล (Tokenize) ผู้เรียนได้ใส่สัญลักษณ์ใดต่อท้ายประโยคคำตอบ เพื่อสอนให้ AI รู้จักหยุดประมวลผลเมื่อตอบเสร็จ?

ตอบ

2. ในการตั้งค่า LoraConfig ผู้เรียนได้ระบุโมดูลเป้าหมาย (Target Modules) ในสมองของ AI เป็นส่วนใดบ้าง? (ระบุอย่างน้อย 3 โมดูล)

ตอบ

ส่วนที่ 2: ผลการประเมินแชทบอท (Evaluation)

1. จากการนำชุดคำถามทดสอบไปประเมินแชทบอท จงบันทึกพฤติกรรมการตอบสนองของโมเดลที่ปรากฏบน Terminal:
 - กรณีที่ 1 ถามคำถามที่ตรงกับข้อมูลใน dataset.json (เช่น สาเหตุที่โบมะเชื้อเทศม่วน) ผลลัพธ์การตอบของ AI คือ:
 - กรณีที่ 2 ถามคำถามหลอกที่ไม่อยู่ในข้อมูล (เช่น "แต่งโมปลุกยังงัยคะ?") ผลลัพธ์การตอบของ AI คือ:
2. จากผลลัพธ์ในกรณีที่ 2 การที่ AI สามารถตอบเรื่องอื่นนอกเหนือจากมะเชื้อเทศได้ สะท้อนให้เห็นถึงคุณลักษณะใดของ Base Model ก่อนนำมาทำ Fine-Tuning?

ตอบ

ส่วนที่ 3: การผสานค่าน้ำหนักและการบันทึกโมเดล (Model Merging & Export)

1. ก่อนทำคำสั่งผสานโมเดล เหตุใดผู้เรียนจึงต้องกำหนดพารามิเตอร์ device_map="cpu" แทนการโหลดเข้าการ์ดจอ (GPU) เหมือนตอนเทรน?

ตอบ

ส่วนที่ 4: การทดลองปรับแต่งโค้ด (Coding Challenges)

คำชี้แจง: ให้ผู้เรียนกลับไปแก้ไขโค้ดตามโจทย์ที่กำหนด สั่งรันโปรแกรมใหม่ และบันทึกผลลัพธ์ที่เปลี่ยนไป

1. กลับไปที่ไฟล์ Fine-tune.py ลองปรับค่า num_train_epochs จากเดิมให้เหลือเพียง 1 รอบ สังเกต
เรนใหม่จนเสร็จ จากนั้นนำโมเดลไปทดสอบด้วยคำถามเดิมในไฟล์ evaluate_model.py
 - ผลลัพธ์: เซทบอทยังคงตอบคำถามเรื่องมะเขือเทศได้แม่นยำและหยุดประโยคได้สมบูรณ์เหมือน
ตอนเทรน 5 รอบหรือไม่? อย่างไร?

ตอบ

.....

.....

.....

2. กลับไปที่ไฟล์ evaluate_model.py ในส่วนของการสร้างคำถาม ลองลบการจัดรูปแบบทิ้ง โดย
เปลี่ยนจาก prompt = f"คำถาม: {q}\nตอบ:" ให้เหลือเพียงการส่งตัวแปรคำถามเพียง ๆ เข้าไป คือ
prompt = q แล้วสั่งรันโปรแกรมใหม่

- ผลลัพธ์: พฤติกรรมการตอบของ AI เปลี่ยนไปอย่างไร? (ยังคงตอบสั้น ๆ แบบผู้เชี่ยวชาญ หรือ
กลับไปมีพฤติกรรมพ่นน้ำลายถามเองตอบเองยาวเหยียดเหมือน Base Model?)

ตอบ

.....

.....

.....

3. ในไฟล์ evaluate_model.py ตรงบรรทัดที่สั่ง model.generate(...) ให้ลองปรับหรือเพิ่ม
พารามิเตอร์จำกัดความยาวเป็น max_new_tokens=5 แล้วสั่งรันโปรแกรม

- ในไฟล์ evaluate_model.py ตรงบรรทัดที่สั่ง model.generate(...) ให้ลองปรับหรือเพิ่ม
พารามิเตอร์จำกัดความยาวเป็น max_new_tokens=5 แล้วสั่งรันโปรแกรม

ตอบ

.....

.....

.....